

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

JIAN LICIO DE OLIVEIRA

**REDUÇÃO DE DIMENSIONALIDADE EM DADOS DO MICROBIOMA
INTESTINAL INFANTIL PARA VISUALIZAÇÃO E INTERPRETAÇÃO DE
DADOS**

MEDIANEIRA

2025

JIAN LICIO DE OLIVEIRA

**REDUÇÃO DE DIMENSIONALIDADE EM DADOS DO MICROBIOMA
INTESTINAL INFANTIL PARA VISUALIZAÇÃO E INTERPRETAÇÃO DE
DADOS**

**Dimensionality Reduction in Infant Gut Microbiome Data for Visualization
and Interpretation**

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito para obtenção do
título de Bacharel em Ciência da Computação
do Curso de Bacharelado em Ciência da
Computação da Universidade Tecnológica
Federal do Paraná.

Orientador(a): Prof. Dr. Davi Pereira Dos Santos

MEDIANEIRA

2025



[4.0 Internacional](https://creativecommons.org/licenses/by-nc-sa/4.0/)

Esta licença permite remixe, adaptação e criação a partir do trabalho, para fins não comerciais, desde que sejam atribuídos créditos ao(s) autor(es) e que licenciem as novas criações sob termos idênticos. Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

JIAN LICIO DE OLIVEIRA

**REDUÇÃO DE DIMENSIONALIDADE EM DADOS DO MICROBIOMA
INTESTINAL INFANTIL PARA VISUALIZAÇÃO E INTERPRETAÇÃO DE
DADOS**

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito para obtenção do
título de Bacharel em Ciência da Computação
do Curso de Bacharelado em Ciência da
Computação da Universidade Tecnológica
Federal do Paraná.

Data de aprovação: 17 / junho / 2025

Davi Pereira Dos Santos
Doutor
Universidade Tecnológica Federal do Paraná

Evando Carlos Pessini
Doutor
Universidade Tecnológica Federal do Paraná

Pedro Luiz de Paula Filho
Doutor
Universidade Tecnológica Federal do Paraná

**MEDIANEIRA
2025**

AGRADECIMENTOS

Agradeço, primeiramente, aos meus pais, pelo suporte incondicional e por todo o esforço em me proporcionar a oportunidade de concluir esta importante etapa da minha vida acadêmica. À minha família, minha eterna gratidão.

Estendo meus agradecimentos aos amigos Jakeline da Silva Andrade e Igor Marcelo S. Lima, pela amizade, incentivo e companheirismo ao longo desta jornada.

Sou profundamente grato a todos os professores que contribuíram com minha formação, em especial ao professor Dr. Everton Coimbra de Araújo, por me inserir em projetos que tiveram — e ainda têm — um impacto significativo na minha trajetória profissional.

Agradeço também à Secretaria do Curso, pela cooperação e apoio prestados ao longo da graduação.

E, sem sombra de dúvidas, não poderia deixar de expressar minha sincera gratidão ao meu orientador, professor Dr. Davi Pereira dos Santos. Sua orientação precisa e comprometida foi essencial para a realização deste trabalho, sobretudo considerando a complexidade e relevância do tema abordado.

A todos que, direta ou indiretamente, contribuíram para a concretização deste TCC, o meu muito obrigado.

“Não posso voltar para ontem, porque eu era
uma pessoa diferente naquela época.” (Carroll,
1865).

RESUMO

O microbioma intestinal tem se destacado como objeto de estudo relevante na compreensão dos fatores que impactam a saúde e o desenvolvimento infantil. Entretanto, a análise desses dados é desafiadora devido à sua alta dimensionalidade, esparsidade e complexidade estrutural. Este trabalho tem como objetivo aplicar técnicas de redução de dimensionalidade (RD) aos dados do microbioma intestinal infantil, visando facilitar sua visualização e interpretação. Para isso, foram utilizados os algoritmos t-Distributed Stochastic Neighbor Embedding (t-SNE) e Multidimensional Scaling (MDS), aplicados a três conjuntos de dados microbiológicos, correspondentes a diferentes tempos de coleta. A metodologia foi estruturada em oito etapas, incluindo tratamento dos dados, definição dos hiperparâmetros, execução dos algoritmos e avaliação das projeções obtidas. Como métricas de avaliação, foram adotados o stress de Kruskal, que mede a distorção das distâncias na redução, e o sortedness, que avalia a preservação da ordem estrutural dos dados após a redução. Os resultados demonstraram que a qualidade dos embeddings variou significativamente conforme o tempo de coleta, o algoritmo utilizado e os hiperparâmetros adotados. De forma geral, observou-se que os dados referentes às crianças com 12 meses de vida apresentaram a melhor organização estrutural, com destaque para a projeção tridimensional gerada pelo MDS, que obteve sortedness global de 0,749 e stress de 0,230, indicando alta fidelidade estrutural. Em contrapartida, os tempos t1 e t2 apresentaram menor capacidade de preservação das relações estruturais, independentemente do método empregado. As análises confirmam que não há uma técnica universalmente superior, sendo necessária a escolha cuidadosa dos parâmetros e do método conforme as características específicas dos dados. Este estudo contribui para a área de bioinformática ao fornecer uma abordagem sistemática para a análise de dados de microbioma por meio de RD, permitindo não apenas a visualização, mas também a interpretação de padrões estruturais que podem estar associados a desfechos clínicos e comportamentais. Como proposta para trabalhos futuros, sugere-se a utilização de métodos interpretáveis, como valores de SHAP, para identificar as espécies bacterianas que mais influenciam na formação dos padrões observados nas projeções, ampliando assim a compreensão sobre o papel do microbioma no desenvolvimento infantil.

Palavras-chave: microbioma; visualização; redução de dimensionalidade.

ABSTRACT

The gut microbiome has emerged as a relevant subject of study in understanding the factors that impact child health and development. However, analyzing this type of data is challenging due to its high dimensionality, sparsity, and structural complexity. This work aims to apply dimensionality reduction (DR) techniques to infant gut microbiome data in order to facilitate its visualization and interpretation. To achieve this, the t-Distributed Stochastic Neighbor Embedding (t-SNE) and Multidimensional Scaling (MDS) algorithms were employed, applied to three microbiological datasets corresponding to different collection time points. The methodology was structured into eight steps, including data preprocessing, hyperparameter definition, algorithm execution, and evaluation of the generated projections. For evaluation metrics, Kruskal's stress was adopted to measure the distortion of distances after dimensionality reduction, and sortedness was used to assess the preservation of the structural order of the data. The results showed that the quality of the embeddings varied significantly according to the collection time, the algorithm used, and the selected hyperparameters. In general, the data from children aged 12 months presented the best structural organization, with emphasis on the three-dimensional projection generated by MDS, which achieved a global sortedness of 0.749 and a stress of 0.230, indicating high structural fidelity. In contrast, the datasets from children aged 3 and 6 months showed lower capacity to preserve structural relationships, regardless of the method used. The analyses confirm that there is no universally superior technique, highlighting the need for careful selection of parameters and methods according to the specific characteristics of the data. This study contributes to the field of bioinformatics by providing a systematic approach for the analysis of microbiome data using DR techniques, enabling not only visualization but also the interpretation of structural patterns that may be associated with clinical and behavioral outcomes. As a proposal for future work, it is suggested to use interpretable methods, such as SHAP values, to identify the bacterial species that most influence the formation of the observed patterns in the projections, thus enhancing the understanding of the microbiome's role in child development.

Keywords: microbiome; visualization; dimensionality reduction.

LISTA DE FIGURAS

Figura 1 – Problemas causados Pela Disbiose.	16
Figura 2 – Categorias e Aplicações do Aprendizado de Máquina.	17
Figura 3 – Descoberta do Conhecimento.	18
Figura 4 – Etapa de seleção de dados.	19
Figura 5 – Etapa de Pré-processamento.	19
Figura 6 – Etapa de Transformação.	20
Figura 7 – Etapa de mineração de dados.	20
Figura 8 – Etapa de avaliação/interpretação.	21
Figura 9 – Redução de Dimensionalidade.	23
Figura 10 – Problema Linear.	24
Figura 11 – Problemas Não Lineares.	25
Figura 12 – Aplicação do Algoritmo LDA Sobre a Base de Dados de Ocorrências Policiais	27
Figura 13 – <i>Stochastic Neighbor Embedding</i> (SNE) para redução de dimensionalidade: (a) duas dimensões, (b) três dimensões.	28
Figura 14 – Resultado da execução do Algoritmo <i>t-Distributed Stochastic Neighbor Embedding</i> (t-SNE) sobre a base de dados de Ocorrências Policiais: (a) Redução dos dados para duas dimensões, (b) Redução dos dados para três dimensões.	29
Figura 15 – Medidas de avaliação de projeções em Redução de Dimensionalidade. ...	33
Figura 16 – Transformações de Redução de Dimensionalidade e Seus Efeitos no <i>Sortedness</i> em Torno de um Ponto Central	34
Figura 17 – Impacto da Aleatorização Progressiva na Estrutura dos Pontos.	34
Figura 18 – Fluxograma de estudo e organização dos dados	46
Figura 19 – Projeções com t-SNE 2D	56
Figura 20 – MDS 2D	57
Figura 21 – t-SNE 3D	58
Figura 22 – MDS 3D	59
Figura 23 – Projeções t-SNE 2D com todas as amostras (classificação por desvio padrão)	60
Figura 24 – Projeções t-SNE 2D com amostras extremas (sem grupo dentro do padrão)	61
Figura 25 – Projeções MDS 2D com todas as amostras (classificação por desvio padrão)	62
Figura 26 – Projeções MDS 2D com amostras extremas (sem grupo dentro do padrão)	62
Figura 27 – t-SNE 3D com todas as categorias: abaixo (vermelho), dentro (cinza) e acima (azul) do desvio padrão. (a) t4, (b) t1, (c) t2.	63
Figura 28 – t-SNE 3D com apenas os grupos extremos: abaixo (vermelho) e acima (azul) do desvio padrão. (a) t4, (b) t1, (c) t2.	64
Figura 29 – MDS 3D Completo	65
Figura 30 – MDS 3D Incompleto	65

LISTA DE TABELAS

Tabela 1 – Interpretação dos valores de <i>stress</i> segundo (Kruskal, 1964)	35
Tabela 2 – Resumo dos hiperparâmetros testados para os algoritmos t-SNE e MDS	54
Tabela 3 – Melhores configurações e métricas para projeções t-SNE 2D	56
Tabela 4 – Métricas de qualidade para projeções MDS 2D	57
Tabela 5 – Melhores configurações e métricas para projeções t-SNE 3D	59
Tabela 6 – Métricas de qualidade para projeções MDS 3D	59
Tabela 7 – Resultado de projeções por tempo, método, dimensão e métrica de distância	67
Tabela 8 – Melhor projeção por tempo de coleta considerando o maior valor de <i>sortedness global</i>	67

LISTA DE ABREVIATURAS E SIGLAS

AM	Aprendizado de Máquina
DII	Doenças Inflamatórias Intestinais
IA	Inteligência Artificial
ISOMAP	<i>Isometric Mapping</i>
LDA	<i>Linear Discriminant Analysis</i>
LE	<i>Laplacian Eigenmap</i>
LLE	<i>Locally Linear Embedding</i>
MDS	<i>Multidimensional Scaling</i>
PCA	<i>Principal Component Analysis</i>
RD	Redução de Dimensionalidade
RNA	Redes Neurais Artificiais
SII	Síndrome do Intestino Irritável
SNE	<i>Stochastic Neighbor Embedding</i>
t-SNE	<i>t-Distributed Stochastic Neighbor Embedding</i>
TEA	Transtorno do Espectro Autista
UMAP	<i>Uniform Manifold Approximation and Projection</i>

SUMÁRIO

1	INTRODUÇÃO	12
1.1	Objetivos geral e específicos	13
1.2	Justificativa.....	13
1.3	Estrutura do trabalho.....	14
2	REFERENCIAL TEÓRICO	15
2.1	Microbioma	15
2.2	Aprendizado de máquina	17
2.2.1	Descoberta de conhecimento	18
2.3	Redes neurais artificiais	20
2.4	Redução de dimensionalidade.....	22
2.4.1	Embedding	23
2.4.2	Problemas lineares	24
2.4.3	Problemas não lineares	25
2.4.4	t-SNE.....	26
2.4.5	MDS	30
2.4.5.1	MDS em comparação com t-SNE e UMAP	30
2.4.5.2	Aplicações do Metric MDS em microbioma e geociências	31
2.4.5.3	Considerações finais em relação ao MDS	31
2.4.6	Sortedness	32
2.4.7	Stress	35
2.5	Escala de Comportamento Adaptativo Vineland	36
2.5.1	Estrutura e Formatos da Vineland-3.....	37
2.5.2	Aspectos Psicométricos e Qualidade Técnica	38
2.5.3	Vineland-3 e o Transtorno do Espectro Autista (TEA)	39
2.5.4	Aplicações em Pesquisa e Intervenção	39
2.6	Trabalhos relacionados	39
3	MATERIAIS E MÉTODOS	43
3.1	Materiais	43
3.1.1	Ambiente de desenvolvimento e ferramentas	43
3.1.2	Base de dados	44
3.2	Métodos	45
3.2.1	Primeira etapa: definição de bases de dados	46
3.2.2	Segunda etapa: tratamento de dados	47
3.2.3	Terceira etapa: implementação da estratégia de modelagem	47
3.2.4	Quarta etapa: modelagem do redutor	48
3.2.5	Quinta etapa: avaliação	48
3.2.6	Sexta etapa: redutor final	49
3.2.7	Sétima etapa: visualização	49
3.2.8	Oitava etapa: análise de achados	50
3.3	Execução dos experimentos	51
3.3.1	Tratamento de dados	51
3.3.2	Implementação da estratégia de modelagem	52
3.3.3	Modelagem dos redutores	52
3.3.3.1	Parâmetros do <i>MDS</i>	53
3.3.3.2	Parâmetros do <i>t-SNE</i>	53
4	RESULTADO E DISCUSSÃO	55

4.1	Projeções em 2D	55
4.1.1	Projeções com t-SNE	55
4.1.2	Projeções com MDS.....	56
4.2	Projeções 3D	57
4.2.1	Projeções com t-SNE 3D	58
4.2.2	Projeções com MDS 3D	58
4.3	Projeções 2D com Classificação por Desvio Padrão	60
4.3.1	Projeções t-SNE 2D com Classificação por Desvio Padrão	60
4.3.2	MDS 2D com Classificação por Desvio Padrão	61
4.4	Projeções 3D com Desvio Padrão.....	62
4.4.1	Projeções t-SNE 3D com Classificação por Desvio Padrão	62
4.4.2	MDS 3D com Classificação por Desvio Padrão	63
5	CONSIDERAÇÕES FINAIS	66
5.1	Conclusão	66
5.2	Trabalhos Futuros.....	68
	REFERÊNCIAS.....	70

1 INTRODUÇÃO

O microbioma humano é composto por trilhões de microrganismos, como bactérias, vírus e fungos, que coexistem em diferentes regiões do corpo, desempenhando funções essenciais à saúde. No trato gastrointestinal, especialmente no intestino grosso, o microbioma atinge alta densidade e diversidade, sendo dominada pelos filos *Bacteroidetes* e *Firmicutes*. Essas comunidades microbianas são responsáveis por funções como a digestão de carboidratos complexos e a síntese de vitaminas essenciais, além de auxiliarem na modulação do sistema imunológico. A compreensão da composição e dinâmica dessas comunidades microbianas é, portanto, uma área de grande interesse científico (Passos, 2024).

Nas últimas décadas, a pesquisa sobre o microbioma avançou, impulsionada pelo desenvolvimento de tecnologias de análise de dados e sequenciamento genômico. Essas ferramentas permitiram explorar as relações entre o microbioma e o estado de saúde, revelando que desequilíbrios ou mudanças significativas na composição microbiana podem estar associados a diversas condições de saúde, incluindo obesidade, doenças gastrointestinais e transtornos do sistema nervoso. Esse crescente corpo de conhecimento destaca o microbioma como um componente fundamental na saúde humana, promovendo a necessidade de estudos que identifiquem e analisem desvios microbianos que possam indicar alterações no organismo (Felice; O'mahony, 2017).

A análise de dados microbiológicos frequentemente enfrenta desafios devido à alta dimensionalidade e variabilidade das informações coletadas. Para lidar com essa complexidade, técnicas de Redução de Dimensionalidade (RD) são amplamente utilizadas, permitindo representar os dados de forma mais compreensível sem comprometer suas relações estruturais essenciais. Conforme discutido na Seção 2.4, a RD aplicada ao microbioma é uma abordagem crucial para tornar dados complexos e de alta dimensionalidade mais interpretáveis. Dados de microbioma apresentam características esparsas e altamente variáveis, o que dificulta sua análise direta. Técnicas de Aprendizado de Máquina (AM), como redes neurais artificiais, e métodos de redução de dimensionalidade, como t-SNE e *Uniform Manifold Approximation and Projection* (UMAP), têm demonstrado eficácia em reduzir dimensões, preservando relações importantes entre os dados (Pereira-Santos *et al.*, 2023). Adicionalmente, métodos clássicos como o *Multidimensional Scaling* (MDS) também se mostram eficazes nesse contexto, ao permitir representar dados esparsos em espaços de baixa dimensionalidade, minimizando a distorção das distâncias originais entre os pontos, o que é especialmente útil em análises de dados microbiológicos que visam a preservação das relações de similaridade entre amostras (Anowar; Sadaoui; Selim, 2021). Essas técnicas permitem representar de forma mais compreensível, facilitando a identificação de padrões, agrupamentos e possíveis relações biológicas que seriam difíceis de perceber em espaços de alta dimensionalidade. Essa abordagem também contribui para uma análise visual mais intuitiva, ampliando a aplicabilidade dos dados em estudos microbiológicos (Pereira-Santos *et al.*, 2023).

1.1 Objetivos geral e específicos

Aplicar técnicas de AM, com ênfase em Redes Neurais Artificiais (RNA) e RD, para analisar padrões microbianos em dados de microbioma infantil, contribuindo para uma melhor compreensão das relações entre microbioma e saúde infantil, e para o desenvolvimento de intervenções clínicas.

- Selecionar atributos de interesse na base de dados do microbioma;
- Utilizar o t-SNE e MDS para criar representações bidimensionais e tridimensionais de dados esparsos de microbioma infantil, facilitando a análise visual e interpretativa;
- Implementar e validar métricas de qualidade das projeções, como o *sortedness*, para avaliar a preservação das relações dos dados originais nas representações reduzidas;
- Criar visualizações 2D e 3D dos resultados obtidos, sendo os gráficos 3D interativos, a fim de facilitar a interpretação dos dados microbiológicos e permitir a identificação de possíveis padrões e agrupamentos relevantes.

1.2 Justificativa

A análise e a RD aplicada ao microbioma infantil é de grande relevância, considerando o impacto decisivo desse período sobre a saúde ao longo da vida. O microbioma se forma no útero e é moldado nos primeiros anos, influenciando o sistema imunológico, metabolismo e funções neurológicas (Felice; O'mahony, 2017; Napolini *et al.*, 2024). No entanto, dados de microbioma são altamente complexos e esparsos, dificultando sua interpretação direta e exigindo abordagens sofisticadas para revelar padrões biológicos relevantes (Napolini *et al.*, 2024; Pereira-Santos *et al.*, 2023).

A utilização de técnicas de RD, como t-SNE, UMAP, MDS e RNA auto-associativas, possibilita transformar dados complexos e esparsos de microbioma em representações mais simples e visualmente interpretáveis (Anowar; Sadaoui; Selim, 2021; Pereira-Santos *et al.*, 2023). O MDS, por sua vez, destaca-se como uma técnica clássica de redução de dimensionalidade que preserva de maneira eficaz as relações globais de similaridade entre amostras, complementando métodos não lineares como o t-SNE e UMAP, que priorizam a preservação de estruturas locais (Anowar; Sadaoui; Selim, 2021; Jaworska; Chupetlovska-anastasova, 2009). Essa combinação de abordagens permite uma avaliação mais abrangente dos dados, auxiliando na identificação de padrões, agrupamentos e relações importantes, além de oferecer compreensões aprofundadas sobre as interações entre o microbioma e os sistemas do organismo infantil (Felice; O'mahony, 2017; Napolini *et al.*, 2024). Para garantir a precisão e a utilidade dessas análises, será implementada a métrica de avaliação da qualidade das projeções *sortedness*, que permite validar a preservação das relações estruturais dos dados originais (Pereira-Santos

et al., 2023). Essa abordagem não apenas avança o entendimento científico sobre o microbioma em desenvolvimento, mas também apoia o desenvolvimento de ferramentas analíticas que beneficiam tanto a pesquisa quanto a prática clínica na promoção da saúde infantil (Naspolini *et al.*, 2024).

1.3 Estrutura do trabalho

Este documento foi estruturado da seguinte forma: No Capítulo 2, foram abordados inicialmente os principais conceitos de AM e, em seguida, explorado o uso de redes neurais artificiais, com ênfase nas técnicas para RD, a fim de apresentar as principais abordagens utilizadas nesse campo de estudo. O Capítulo 3 foi dedicado aos materiais e métodos, detalhando todas as etapas planejadas para o desenvolvimento do projeto.

- **Capítulo 1 - Introdução:** Apresenta o contexto geral do estudo, destacando a relevância do tema, os objetivos geral e específicos, a justificativa e uma visão geral sobre a importância das técnicas de RD aplicadas ao microbioma.
- **Capítulo 2 - Referencial Teórico:** Reúne os conceitos fundamentais que embasam o trabalho, incluindo microbioma, AM e técnicas de RD, como t-SNE, MDS e *UMAP*, além de metodologias associadas à análise de dados microbiológicos.
- **Capítulo 3 - Materiais e Métodos:** Detalha o ambiente de desenvolvimento, as ferramentas utilizadas e a abordagem metodológica, abrangendo as etapas de pré-processamento dos dados, aplicação das técnicas de RD, desenvolvimento das visualizações interativas e avaliação das projeções geradas.
- **Capítulo 4 - Desenvolvimento e Resultados:** Apresenta a aplicação prática das técnicas de t-SNE e MDS sobre os dados de microbioma infantil, incluindo a execução das projeções em 2D e 3D, análise da qualidade das representações por meio da métrica *sortedness*, geração de gráficos interativos e discussão dos padrões observados.
- **Capítulo 5 - Conclusão e Trabalhos Futuros:** Traz as conclusões obtidas a partir dos resultados alcançados, refletindo sobre as contribuições do estudo para o entendimento do microbioma infantil, além de propor direções para trabalhos futuros e possíveis aprimoramentos das técnicas aplicadas.

Essa estrutura foi elaborada com o objetivo de proporcionar uma narrativa lógica e coerente, facilitando a compreensão das etapas e dos resultados obtidos ao longo do estudo.

2 REFERENCIAL TEÓRICO

Neste Capítulo são abordados tópicos relacionados ao microbioma (Seção 2.1), tais como suas características e importância para o corpo humano. Posteriormente, aborda-se aprendizado de máquina (Seção 2.2), RNA (Seção 2.3) e por fim RD (Seção 2.4)

2.1 Microbioma

O conceito de microbioma tem se destacado como um tema essencial nas pesquisas relacionadas à saúde humana, devido à sua complexidade e relevância para diversos processos biológicos. Esse termo refere-se ao conjunto de microrganismos microscópicos, incluindo vírus, bactérias, arqueias e fungos, que habitam diferentes ambientes, como a pele e todas as mucosas do corpo humano, incluindo as regiões esofágica, gástrica, intestinal, urinária, genital, respiratória, oral e oftálmica. Além disso, microbiomas são encontrados em ambientes externos, como solo, plantas, animais águas doces e marinhas, efluentes e resíduos. A popularização do conceito ocorreu em 2001, pelo microbiologista Joshua Lederberg, que destacou a comunidade de microrganismos comensais, simbióticos e patogênicos que compartilham o espaço corporal humano e desempenham papéis fundamentais na manutenção da saúde e no desenvolvimento de doenças (Faintuch, 2017).

Historicamente, a investigação do microbioma era realizada por meio de técnicas microbiológicas clássicas, como esfregaço, coloração, microscopia, cultivo e clonagem. No entanto, estudos sobre o microbioma intestinal evidenciaram que a maioria das bactérias presentes nesse ambiente era de difícil identificação, principalmente devido à sua característica estritamente anaeróbica e ao desconhecimento de sua biologia, o que impedia seu crescimento em cultivos convencionais. Além disso, a vasta diversidade microbiana tornava inviável o isolamento e a descrição individual de cada organismo. Para superar essas limitações, surgiram as técnicas de identificação em larga escala, que permitiram a categorização dos microrganismos por filos e famílias. Com a extração de ácidos nucleicos ou das subunidades pequenas do RNA ribossômico (16S rRNA) a partir do DNA fecal total, o sequenciamento automatizado possibilitou avanços significativos nesse campo. Dessa forma, o sequenciamento metagenômico, especialmente do 16S rRNA, tornou-se essencial para os estudos do microbioma, proporcionando uma visão mais abrangente sobre sua composição e suas interações no organismo humano (Faintuch, 2017).


A identificação de microrganismos específicos, como o *Helicobacter pylori*, revolucionou a compreensão do microbioma gástrico ao desafiar a concepção de que o estômago seria um ambiente estéril. Conforme descrito por Faintuch (2017), avanços em técnicas de microbiologia molecular permitiram detectar microrganismos anteriormente não identificáveis por cultura, revelando que cerca de 70% do microbioma intestinal humano era desconhecido. Entre esses microrganismos, destaca-se a proteobactéria *H. pylori*, presente em mais da metade da população mundial. O estômago humano, apesar de seu pH ácido, abriga uma comunidade microbiana

diversa, com densidade variando de 10^1 a 10^3 unidades formadoras de colônias (UFC/g), composta majoritariamente pelos filos *Firmicutes*, *Bacteroidetes*, *Actinobacteria*, *Proteobacteria* e *Fusobacteria*, além de gêneros como *Streptococcus* e *Prevotella*. Evidências preliminares sugerem que alterações na composição desse microbioma podem estar relacionadas a lesões gástricas induzidas por *H. pylori*, como gastrite atrófica ou metaplasia intestinal, bem como ao uso prolongado de inibidores da secreção ácida. Essas modificações impactam a homeostase gástrica e podem favorecer o desenvolvimento de doenças, incluindo o adenocarcinoma. Faintuch (2017) ainda ressalta que tais alterações no microbioma desempenham um papel importante nesse processo patológico. A elucidação dessas interações entre microbioma e infecção por *H. pylori* abre caminho para novas abordagens profiláticas e terapêuticas.

Essas modificações impactam a homeostase gástrica e podem favorecer o desenvolvimento de doenças, incluindo o adenocarcinoma. Faintuch (2017) ainda ressalta que essas alterações no microbioma, especialmente em casos de infecção por *H. pylori*, desempenham um papel importante nesse processo. A elucidação dessas interações entre microbioma e infecção por *H. pylori* abre caminho para novas abordagens profiláticas e terapêuticas.

O microbioma humano desempenha papel essencial na regulação de processos metabólicos, imunológicos e inflamatórios, sendo crucial para a manutenção da saúde e prevenção de doenças. A Figura 1 ilustra os impactos da disbiose, destacando sua associação com diversos problemas de saúde. Alterações no equilíbrio microbiano, conhecidas como disbiose, estão associadas a uma ampla gama de condições, como doenças pancreáticas, obesidade, doenças inflamatórias intestinais (DIIs), doenças hepáticas gordurosas não alcoólicas (DHGNA), complicações renais e distúrbios metabólicos relacionados ao risco cardiometabólico. A interação entre o microbioma e o sistema imunológico influencia diretamente respostas inflamatórias e metabólicas, enquanto fatores como dieta, estilo de vida e infecções moldam sua composição. Estratégias baseadas na modulação do microbioma, incluindo probióticos, simbióticos e transplantes fecais, têm se mostrado promissoras na prevenção e manejo dessas condições, oferecendo potencial para terapias personalizadas (Faintuch, 2017).

Figura 1 – Problemas causados Pela Disbiose.




Fonte: Passos (2024).

2.2 Aprendizado de máquina

Conforme destacado por Artero (2008), o AM pode ser subdividido em duas categorias principais: aprendizado supervisionado e não supervisionado. Ludermir (2021) apresenta outra ramificação, que é o aprendizado por reforço. A partir da representação esquemática apresentada na Figura 2, torna-se mais clara a distinção entre essas abordagens. Segundo Lima, Pinheiro e Oliveira (2014), o AM tem como propósito o estudo e o desenvolvimento de métodos computacionais capazes de construir sistemas que adquiram conhecimento de maneira automatizada.

Figura 2 – Categorias e Aplicações do Aprendizado de Máquina.



Fonte: Adaptado de Ludermir (2021), Artero (2008).

No Aprendizado Supervisionado, cada exemplo fornecido ao algoritmo deve vir acompanhado de uma resposta correta, que indica a classe à qual pertence. Um caso típico seria a tarefa de identificar se uma imagem contém um gato ou um cachorro. Cada exemplo é descrito por um conjunto de valores que representam seus atributos e por um rótulo correspondente à sua classe. O objetivo principal do algoritmo é desenvolver um modelo capaz de classificar corretamente novos exemplos ainda não identificados. Quando as classes possuem valores finitos e distintos, o problema é denominado classificação; já no caso de valores contínuos, trata-se de uma regressão. Esse tipo de aprendizado é amplamente adotado em diversas aplicações (Ludermir, 2021).

No Aprendizado Não Supervisionado, os dados são apresentados ao algoritmo sem informações prévias sobre a classificação ou rótulos associados. O algoritmo analisa as características dos dados e organiza os exemplos em grupos, chamados de agrupamentos, com base nas semelhanças entre seus atributos. Esse processo ocorre de forma autônoma, sem


intervenção humana direta na definição dos grupos. Após a criação dos agrupamentos, é comum realizar uma análise para interpretar e compreender o significado de cada agrupamento no contexto do problema em questão.

No Aprendizado por Reforço, o algoritmo não recebe a solução certa diretamente, mas sim uma sinalização de reforço, que pode ser representada por uma recompensa ou uma punição. A partir dos exemplos fornecidos, o algoritmo formula hipóteses e verifica se essas hipóteses resultaram em desempenhos positivos ou negativos. Esse tipo de aprendizado é amplamente utilizado em áreas como jogos e robótica, sendo a técnica aplicada no desenvolvimento do *AlphaGo* (Ludermir, 2021).

2.2.1 Descoberta de conhecimento

A descoberta de conhecimento é um processo complexo e iterativo para identificar padrões válidos, novos, úteis e compreensíveis em grandes volumes de dados. Envolve uma série de etapas que incluem a seleção, preparação, transformação, aplicação de métodos de mineração de dados para extração de padrões e a avaliação e interpretação dos resultados. O objetivo central é transformar dados brutos, muitas vezes complexos e volumosos, em informações que possam ser compreendidas e utilizadas para suportar decisões ou gerar novos conhecimentos. Esse processo é interdisciplinar, integrando áreas como estatística, AM, Inteligência Artificial (IA) e banco de dados para lidar com os desafios do excesso de informações na era digital e atender a diferentes necessidades práticas e científicas (Fayyad; Piatetsky-shapiro; Smyth, 1996). Conforme ilustrado na Figura 3, esse processo pode ser visualizado de forma esquemática.


Figura 3 – Descoberta do Conhecimento.



Fonte: Adaptado de (Fayyad; Piatetsky-shapiro; Smyth, 1996).

A etapa inicial consiste na seleção de dados, em que se identificam e extraem, de uma base mais ampla, apenas as informações relevantes para a análise. Esse procedimento tem como objetivo restringir o conjunto original a um escopo manejável e alinhado com a tarefa de mineração de dados, descartando atributos irrelevantes ou redundantes. O resultado é um subconjunto de dados mais coerente e eficiente para as etapas seguintes do processo de descoberta de conhecimento. A Figura 4 apresenta uma representação visual dessa etapa.


Figura 4 – Etapa de seleção de dados.



Fonte: Adaptado de (Fayyad; Piatetsky-shapiro; Smyth, 1996).

Na etapa de pré-processamento, os dados selecionados previamente passam por um tratamento que visa garantir sua qualidade e consistência. São realizadas ações como remoção de ruídos, preenchimento de valores ausentes e normalização, assegurando que os dados estejam em condições adequadas para as etapas seguintes. A Figura 5 apresenta essa fase, em que os dados são preparados para transformação.


Figura 5 – Etapa de Pré-processamento.



Fonte: Adaptado de (Fayyad; Piatetsky-shapiro; Smyth, 1996).

A etapa de transformação consiste na conversão dos dados pré-processados em formatos ou representações mais apropriadas para análise. Nessa fase, podem ser criados novos atributos, realizadas agregações ou aplicadas técnicas de redução de dimensionalidade. O objetivo é facilitar a ação dos algoritmos de mineração, que operam sobre esse conjunto transformado. Essa etapa é representada na Figura 6.

Em seguida, ocorre a mineração de dados, considerada o núcleo do processo. Nessa fase, são aplicados algoritmos com o propósito de identificar padrões ou modelos relevantes nos

Figura 6 – Etapa de Transformação.

Fonte: Adaptado de Fayyad, Piatetsky-Shapiro e Smyth (1996).

dados transformados. Técnicas como classificação, agrupamento e regras de associação são comumente empregadas para extrair informações significativas. A Figura 7 ilustra esse estágio, em que o conhecimento começa a emergir dos dados.

Figura 7 – Etapa de mineração de dados.


Fonte: Adaptado de Fayyad, Piatetsky-Shapiro e Smyth (1996).

Por fim, a etapa de avaliação e interpretação tem como objetivo validar os padrões descobertos, analisando sua utilidade, relevância e aplicabilidade prática. Os resultados são organizados e interpretados de forma a permitir sua compreensão e utilização, possibilitando a geração de conhecimento que apoie decisões estratégicas. A Figura 8 representa esse momento final do processo.

2.3 Redes neurais artificiais

O trabalho em RNA tem sido motivado desde o início pelo reconhecimento de que o cérebro humano processa informações de maneira completamente diferente de um computador digital convencional. O cérebro é um sistema de processamento de informações altamente complexo, não linear e paralelo, possuindo a capacidade de organizar seus componentes estruturais, conhecidos como neurônios, para realizar determinados processamentos, como o reco-

Figura 8 – Etapa de avaliação/interpretação.



Fonte: Adaptado de Fayyad, Piatetsky-Shapiro e Smyth (1996).

nhecimento de padrões, percepção e controle motor, de forma muito mais rápida do que o mais avançado computador digital disponível atualmente (Haykin, 2007).

A visão humana, que é uma tarefa de processamento de informações, realiza operações de maneira significativamente mais veloz e eficiente. A função do sistema visual é fornecer uma representação do ambiente ao redor e, mais importante, disponibilizar as informações necessárias para a interação com esse ambiente. O cérebro executa, rotineiramente, tarefas complexas, como o reconhecimento de um rosto familiar em uma cena desconhecida, em cerca de 100-200 milissegundos, enquanto computadores convencionais demandam um tempo significativamente maior para processar informações menos complexas (Haykin, 2007).

Outro exemplo relevante é o sonar dos morcegos, um sistema ativo de localização por eco. Além de identificar a distância de um alvo, o sonar também transmite informações sobre sua velocidade relativa e outras características, como elevação e direção. Esse mecanismo permite que os morcegos realizem cálculos extremamente rápidos para perseguir ou evitar obstáculos. Esse nível de processamento evidencia a eficiência do cérebro na execução de tarefas em tempo real (Haykin, 2007).

A plasticidade do cérebro, ou seja, sua capacidade de se adaptar ao ambiente, é essencial para seu desenvolvimento e funcionamento. Essa plasticidade é especialmente evidente nos primeiros anos de vida, mas continua em algum nível ao longo da existência. Neurônios em desenvolvimento são sinônimos de cérebros plásticos, adaptando-se às demandas ambientais de forma notável. Essa característica também é replicada em redes neurais artificiais, que modelam a maneira como o cérebro executa tarefas específicas. Redes neurais artificiais são implementadas utilizando-se componentes eletrônicos ou simulados via programação computacional. Elas realizam computação por meio de aprendizado, ajustando suas conexões com base na experiência, de forma semelhante ao cérebro humano (Haykin, 2007).

Essencialmente, uma rede neural é um processador distribuído que opera paralelamente e é composto por unidades simples, com capacidade de armazenamento distribuído. Sua funcionalidade depende da aquisição de conhecimento através de conexões sinápticas e de sua capacidade de adaptar-se a novos padrões. O desenvolvimento e o aprendizado de redes neu-

rais baseiam-se em algoritmos específicos que ajustam os pesos sinápticos, permitindo que estas aprendam a partir de exemplos e otimizem seu desempenho para tarefas específicas. Este processo inspira-se em conceitos biológicos, como a plasticidade cerebral e o aprendizado experiencial, que fundamentam tanto os sistemas biológicos quanto os artificiais. Dessa forma, redes neurais são projetadas para simular a complexidade e eficiência do processamento cerebral humano (Haykin, 2007).

Para Russell e Norvig (2013), as RNAs são sistemas computacionais inspirados no cérebro humano, compostos por nós conectados por ligações direcionadas. Cada ligação tem um peso associado, que regula a força de conexão entre os nós. A ativação de cada nó é determinada por uma soma ponderada das entradas, seguida da aplicação de uma função de ativação, como a função sigmoide. Existem dois tipos principais de redes: as de alimentação para frente *feedforward*¹, que não possuem ciclos, e as recorrentes, que permitem *feedback*² e podem modelar memória de curto prazo. As RNA podem ter camadas únicas ou múltiplas, aonde camadas ocultas possibilitam a representação de funções não lineares complexas. O treinamento dessas redes geralmente utiliza algoritmos como a retro propagação, baseada em gradiente descendente, para ajustar os pesos e minimizar o erro.

2.4 Redução de dimensionalidade

Um dos principais desafios relacionados à análise de dados é a dificuldade de lidar com a complexidade e a alta dimensionalidade desses dados. A dimensão é representada pela quantidade de atributos necessários para descrever os dados, e essa elevada dimensionalidade dificulta a visualização gráfica, tornando a análise e interpretação mais complicadas (Lopes, 2020).


A Figura 9 ilustra o processo de RD permite representar dados originalmente distribuídos em um espaço de maior dimensionalidade em espaços de menor dimensionalidade. No exemplo apresentado, a projeção inicia-se a partir de um conjunto de dados em três dimensões ($D = 3$), aonde os dados estão organizados em uma estrutura cúbica. A redução para duas dimensões ($D = 2$) resulta em uma representação bidimensional, na qual parte da informação tridimensional é comprimida, preservando, sempre que possível, as relações estruturais do conjunto de dados original. Por fim, a transformação para uma única dimensão ($D = 1$) simplifica ainda mais os dados, reduzindo sua representação a uma escala linear. Esse processo evidencia como a RD pode ser utilizada para facilitar a visualização e análise de dados altamente complexos, tornando-os mais acessíveis para interpretação e exploração.

O processo de RD busca atenuar esses problemas ao diminuir a complexidade dos dados por meio de algoritmos que reduzem a dimensionalidade para níveis que podem ser representados graficamente (duas ou três dimensões), mantendo, na medida do possível, as distâncias da dimensão original. Para isso, esses algoritmos utilizam métodos matemáticos e

¹ Propagação direta

² Retroalimentação

Figura 9 – Redução de Dimensionalidade.



Fonte: Bishop (2006).

estatísticos. Na literatura, existem vários algoritmos de RD, que podem ser agrupados em dois principais tipos: problemas lineares e problemas não lineares (Lopes, 2020).

2.4.1 Embedding

Embedding é um método utilizado para mapear dados de alta dimensionalidade para um espaço de baixa dimensionalidade, preservando suas propriedades estruturais e relacionais. Essa técnica é amplamente empregada em AM e análise de dados para representar entidades como genes, proteínas ou documentos em vetores compactos que capturam informações essenciais sobre suas relações ou características (Su *et al.*, 2020).


O uso de *embedding* pode ser observado em diferentes etapas do processo de descoberta de conhecimento. Para a etapa de transformação, discutido na seção ??, *embedding* são aplicados principalmente para reduzir a dimensionalidade e organizar dados complexos. Por exemplo, técnicas como *Principal Component Analysis* (PCA) e t-SNE projetam dados de alta dimensão em um espaço menor, facilitando o processamento subsequente por algoritmos de mineração ou aprendizado de máquina. O objetivo nesta fase é otimizar o formato para a mineração de dados, mas sem necessariamente torná-los diretamente interpretáveis. O *embedding*, quando aplicado à avaliação, facilita a identificação de padrões em dados complexos, como microbiológicos ou genéticos, e permite que métricas específicas, como *sortedness*, sejam utilizadas para medir a capacidade das representações de ordenar ou agrupar os dados conforme critérios definidos. Além disso, ele contribui para *insights* qualitativos sobre a estrutura dos dados, auxiliando os pesquisadores tanto na validação de hipóteses quanto na formulação de novas questões ou ideias (Su *et al.*, 2020).

2.4.2 Problemas lineares

As técnicas lineares têm como principais representantes o PCA e o MDS. Esses algoritmos focam em manter a representação de pontos de dados distantes na baixa dimensionalidade (Lopes, 2020).

A Figura 10 ilustra a aplicação do algoritmo *PCA*, uma técnica amplamente utilizada para RD em problemas lineares. O gráfico apresenta um conjunto de pontos distribuídos em um espaço bidimensional, aonde o PCA identifica as direções de maior variância dos dados, conhecidas como componentes principais (*Principal Components* - PCs). No gráfico, as setas representam os dois principais eixos de variação dos dados: PC1 e PC2. O eixo PC1 corresponde à direção que captura a maior variação presente no conjunto de dados, enquanto PC2 é ortogonal a PC1 e captura a segunda maior variação. A projeção dos dados sobre esses componentes reduz a dimensionalidade ao concentrar a informação nas direções mais relevantes. Esse processo é essencial para simplificar a estrutura dos dados e facilitar sua análise sem perda significativa de informação. A separação entre os pontos, evidenciada no gráfico, demonstra como o PCA organiza os dados de forma que padrões subjacentes se tornem mais evidentes. Essa técnica, segundo Lopes (2020), é eficaz para problemas aonde as relações entre os dados podem ser expressas linearmente, sendo frequentemente aplicada em diversas áreas, como processamento de imagens, bioinformática e reconhecimento de padrões.

Figura 10 – Problema Linear.




Fonte: Lopes (2020).

Os algoritmos lineares focam em preservar as distâncias entre pontos de dados na nova representação de baixa dimensionalidade. No entanto, são limitados a problemas linearmente separáveis, o que reduz significativamente seu campo de aplicação (Lopes, 2020).

2.4.3 Problemas não lineares

Algoritmos não lineares têm como objetivo manter as estruturas de alta dimensão na nova dimensão reduzida. Apesar de serem mais versáteis e eficazes do que os lineares, por resolverem uma gama maior de problemas, esses algoritmos apresentam maior complexidade computacional. Isso dificulta sua aplicação em cenários de *Big Data*, pois o tempo de processamento pode se tornar proibitivamente longo (Lopes, 2020). Na Figura 11, são apresentados gráficos de representações tridimensionais de conjuntos de dados sintéticos utilizados para avaliar algoritmos de RD. Os exemplos incluem: Rolo Espiral (*Swiss Roll*), aonde os dados estão enrolados em forma de espiral, Hélice (*Helix*), que apresenta uma estrutura helicoidal, Picos Gêmeos (*Twinpeaks*), caracterizado por duas superfícies onduladas e paralelas e Interseção (*Intersect*), que se assemelha ao símbolo do infinito, aonde os dados se cruzam em uma configuração tridimensional específica.

Figura 11 – Problemas Não Lineares.



Fonte: (Lopes, 2020).

Essa limitação dos algoritmos não lineares frequentemente inviabiliza sua aplicação em grandes volumes de dados, já que o processamento pode ultrapassar o tempo necessário para a utilização prática dos resultados. Um dos algoritmos não lineares mais utilizados é o t-SNE, desenvolvido por (Maaten; Hinton, 2008). Esse algoritmo utiliza probabilidade condicional para representar a similaridade entre dados nas dimensões reduzidas e originais. Por empregar a função de custo baseada na distribuição *t-student*, que possui caudas mais largas que a gaussiana, o t-SNE apresenta resultados visuais mais precisos, mas enfrenta um sério problema de escalabilidade, já que seu tempo de processamento cresce exponencialmente com o aumento do volume de dados (Lopes, 2020).

2.4.4 t-SNE

Desenvolvido por Maaten e Hinton (2008), foi criado como uma alternativa para superar limitações como problema de aglomeração (*crowding problem*) e a dificuldade de otimização presentes em métodos como o SNE. O objetivo é converter dados de alta dimensionalidade em mapas de baixa dimensionalidade, preservando a qualidade tanto das estruturas locais, quanto parcialmente, as globais. No entanto, é importante destacar que o t-SNE é uma técnica de redução de dimensionalidade não supervisionada, o que significa que os novos eixos gerados na projeção de menor dimensão não correspondem diretamente a atributos originais dos dados. Em vez disso, os eixos representam combinações não lineares das variáveis originais, enfatizando a proximidade relativa entre os pontos para melhor visualização de padrões e agrupamentos. Em relação ao SNE, o t-SNE usa distribuição *t-Student* no lugar de Gaussiana para calcular as similaridades no espaço de baixa dimensionalidade, reduzindo o problema de aglomeração, outro fator importante para se destacar é que usa uma versão simétrica da função de custo do SNE, simplificando o cálculo do gradiente. Existe uma clareza superior na visualização de dados usando t-SNE, em relação a outros algoritmos como *Isomap*, *Locally Linear Embedding* (LLE) e *Sammon Mapping* (Maaten; Hinton, 2008).

Uma das vantagens observadas no t-SNE foi sua capacidade de organizar os dados de maneira uniforme no espaço reduzido, evitando a concentração excessiva de pontos no centro, característica frequentemente notada em outros algoritmos. Isso ocorre devido à utilização de forças atrativas e repulsivas no cálculo da distribuição dos dados. Essa propriedade permite que o t-SNE crie representações em que as distâncias entre os pontos são mais fiéis à estrutura dos dados originais.


As representações geradas pelo SNE e pelo t-SNE estão ilustradas, respectivamente, nas Figuras 13 e 14. A Figura 13 apresenta os resultados do SNE, com (a) mostrando a redução para duas dimensões e (b) para três dimensões. Apesar de fornecer uma representação dos dados reduzidos, observa-se que o SNE apresenta maior sobreposição entre os grupos, dificultando a identificação de padrões.

Em contrapartida, a Figura 14 exibe os resultados do t-SNE, um algoritmo projetado para converter dados de alta dimensionalidade em mapas de baixa dimensionalidade, mantendo tanto as estruturas locais quanto, parcialmente, as globais. A subfigura (a) apresenta a redução para duas dimensões, enquanto (b) mostra a projeção tridimensional. Este método demonstrou sua eficácia ao organizar os dados de maneira uniforme no espaço reduzido, preservando melhor as relações locais e fornecendo uma visualização mais interpretável. Isso facilita a separação entre grupos e destaca nuances adicionais na representação tridimensional.

Os resultados do t-SNE podem ser observados nas figuras do documento que ilustram sua aplicação em uma base de dados de ocorrências policiais. As Figuras 13 e 14 apresentam os resultados obtidos pelo SNE e pelo t-SNE, respectivamente, ambos reduzindo os dados para duas dimensões. Nessas figuras, o t-SNE demonstrou uma maior clareza na separação dos padrões presentes nos dados em comparação ao SNE, facilitando a interpretação visual.

Adicionalmente, a Figura 12 exibe o resultado da execução do Algoritmo LDA sobre a base de dados de ocorrências policiais em duas dimensões, mostrando padrões inferiores em relação ao t-SNE. Esses resultados reforçam a superioridade do t-SNE na preservação da estrutura original dos dados durante a redução dimensional.

Figura 12 – Aplicação do Algoritmo LDA Sobre a Base de Dados de Ocorrências Policiais



Fonte: Lopes (2020).

Além disso, a eficiência do t-SNE foi amplamente validada na visualização de dados em cenários reais, como dados relacionados a segurança pública, educação e saúde. A combinação entre desempenho visual e precisão dos resultados posiciona o t-SNE como uma ferramenta essencial para problemas de redução de dimensionalidade que exigem representações visuais de alta qualidade.

No espaço de alta dimensionalidade, as distâncias entre pontos x_i são convertidas em probabilidades condicionais $p_{j|i}$, que indicam a probabilidade de x_j ser um vizinho de x_i (Maaten; Hinton, 2008). Estas probabilidades são mostradas na Equação 1, aonde σ_i é o desvio padrão ajustado para obter uma perplexidade fixa.


$$p_{j|i} = \frac{\exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma_i^2}\right)}{\sum_{k \neq i} \exp\left(-\frac{\|x_i - x_k\|^2}{2\sigma_i^2}\right)}, \quad (1)$$

Para evitar problemas de assimetria, as probabilidades p_{ij} são definidas como mostrado na Equação 2, aonde n é o número total de pontos (Maaten; Hinton, 2008).

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}, \quad (2)$$

No espaço de baixa dimensionalidade, as probabilidades q_{ij} são calculadas usando uma distribuição *t-Student* com um grau de liberdade, a qual, conforme explicado por Maaten e Hinton (2008), ajuda a lidar com o problema de aglomeração, permitindo que distâncias moderadas

Figura 13 – SNE para redução de dimensionalidade: (a) duas dimensões, (b) três dimensões.



Fonte: Lopes (2020).

no espaço de alta dimensionalidade sejam representadas como distâncias maiores no espaço reduzido, conforme definido na Equação 3:

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}. \quad (3)$$


A função de custo do t-SNE minimiza a divergência entre as distribuições P (do espaço de alta dimensionalidade) e Q (do espaço de baixa dimensionalidade) (Maaten; Hinton, 2008). Essa função é definida pela Equação 4.

$$C = \sum_i \sum_j p_{ij} \log \frac{p_{ij}}{q_{ij}}. \quad (4)$$


O t-SNE utiliza a descida do gradiente para minimizar a função de custo (Maaten; Hinton, 2008). O gradiente é definida pela Equação 5:

$$\frac{\partial C}{\partial y_i} = 4 \sum_j (p_{ij} - q_{ij}) (1 + \|y_i - y_j\|^2)^{-1} (y_i - y_j). \quad (5)$$

Figura 14 – Resultado da execução do Algoritmo t-SNE sobre a base de dados de Ocorrências Policiais: (a) Redução dos dados para duas dimensões, (b) Redução dos dados para três dimensões.



(a)



(b)

Fonte: Lopes (2020).

2.4.5 MDS

O MDS é uma técnica clássica de RD que busca representar objetos de um espaço de alta dimensionalidade em um espaço de menor dimensionalidade, preservando, tanto quanto possível, as distâncias entre as amostras (Ghojogh *et al.*, 2020). O MDS é amplamente empregado em diversas áreas, como psicologia, química, biologia e geociências, conforme apontado por Jaworska e Chupetlovska-Anastasova (2009), Nordsvan *et al.* (2020), sendo considerado uma das abordagens mais antigas e fundamentais em RD (Ghojogh *et al.*, 2020).

O MDS é classificado em três categorias principais: MDS clássico (Classical MDS ou PCoA), MDS métrico (Metric MDS) e MDS não-métrico (Ghojogh *et al.*, 2020). Neste trabalho, o foco recai sobre o MDS métrico, que busca preservar as distâncias entre amostras a partir de uma matriz de dissimilaridade pré-computada, podendo utilizar diferentes métricas de distância, como *Bray-Curtis*, *Canberra* e *Manhattan*. Essa flexibilidade torna o método aplicável a conjuntos de dados esparsos e complexos, como os utilizados neste estudo (Ghojogh *et al.*, 2020).

No MDS métrico, o objetivo é encontrar as coordenadas Y no espaço de menor dimensionalidade que minimizem a função de *stress*, cuja formulação e implicações estão detalhadas na Seção 2.4.7. Como essa função não possui solução fechada, a otimização é realizada de forma iterativa, empregando algoritmos como o SMACOF (*Scaling by Majorizing a Complicated Function*) (Ghojogh *et al.*, 2020).

Neste trabalho, a principal métrica adotada para avaliar a qualidade das projeções será o *sortedness* global e local, por sua capacidade de avaliar diretamente a preservação das relações estruturais dos dados no espaço embutido (Pereira-Santos *et al.*, 2023). A métrica de *stress* será utilizada de forma complementar, oferecendo uma medida adicional da qualidade do ajuste das distâncias entre os espaços original e reduzido.

2.4.5.1 MDS em comparação com t-SNE e UMAP

O MDS métrico, ao utilizar uma matriz de dissimilaridade pré-computada, busca preservar as distâncias globais entre as amostras no espaço de menor dimensionalidade, independentemente da métrica utilizada (Ghojogh *et al.*, 2020). Essa característica proporciona uma visualização mais fiel das relações de similaridade em todo o conjunto de dados, sendo especialmente útil em contextos em que a manutenção das distâncias relativas entre as amostras é essencial para a interpretação dos padrões globais (Nordsvan *et al.*, 2020).

Entre as principais vantagens do MDS métrico destacam-se sua flexibilidade no uso de diferentes métricas de dissimilaridade, sua robustez e sua natureza determinística, o que elimina a variabilidade associada a inicializações aleatórias, comum em métodos não-lineares como o t-SNE (Ghojogh *et al.*, 2020). Além disso, o MDS métrico oferece controle direto sobre o nível de ajuste por meio da função de *stress*, permitindo avaliar de forma objetiva o quão bem as distâncias são preservadas na projeção.

Entretanto, o MDS métrico possui limitações notáveis em dados que apresentam distribuições não-lineares complexas ou estruturas de manifold, aonde técnicas não-lineares como o t-SNE e o UMAP tendem a produzir representações visuais mais eficazes, particularmente na preservação de vizinhanças locais (Anowar; Sadaoui; Selim, 2021). Tais técnicas priorizam as relações locais e podem facilitar a identificação de agrupamentos densos, embora frequentemente à custa da distorção global das distâncias (Ghojogh *et al.*, 2020).

Além disso, diferentemente do t-SNE e do UMAP, que incluem mecanismos internos para ajustar a compactação e a separação de clusters através de hiperparâmetros como *perplexity* e *n_neighbors*, o MDS métrico não possui mecanismos dedicados para tal ajuste, tornando-o menos flexível em situações que demandam representações compactas de agrupamentos em espaços altamente complexos.

Dessa forma, o MDS métrico permanece uma abordagem robusta e confiável para preservar estruturas globais em dados esparsos e de alta dimensionalidade, sendo uma técnica complementar aos métodos não-lineares em análises exploratórias e comparativas.

2.4.5.2 Aplicações do Metric MDS em microbioma e geociências

O MDS métrico tem sido amplamente empregado em diversas áreas, incluindo a geocronologia de zircões detríticos, aonde é utilizado para gerar mapas bidimensionais que auxiliam na identificação de padrões de proveniência e agrupamentos composicionais (Nordsvan *et al.*, 2020). Esse campo, abordado em mais detalhes na Seção 2.4.7, utiliza o MDS métrico para representar as dissimilaridades globais entre amostras, embora suas limitações fiquem evidentes quando há diferenças significativas nas incertezas analíticas dos dados, impactando a interpretação das projeções baseadas no *stress* (Nordsvan *et al.*, 2020).

No campo da análise de microbioma, o uso do MDS métrico é menos frequente em comparação com métodos não-lineares como o t-SNE e o UMAP, que tendem a ser preferidos devido à sua capacidade de enfatizar estruturas locais e agrupamentos densos (Anowar; Sadaoui; Selim, 2021). Contudo, o MDS métrico pode fornecer visualizações globais complementares, especialmente quando combinado com métricas alternativas à euclidiana, permitindo explorar padrões de dissimilaridade mais amplos em dados esparsos e de alta dimensionalidade.

2.4.5.3 Considerações finais em relação ao MDS

Diante de suas características, o MDS métrico permanece uma abordagem robusta, determinística e interpretável, especialmente útil para representar relações globais em conjuntos de dados esparsos e complexos. Contudo, suas limitações na captura de estruturas não-lineares destacam a importância de seu uso complementar a técnicas não-lineares, como o t-SNE e o UMAP, permitindo análises mais abrangentes e ricas em diferentes contextos exploratórios.

2.4.6 Sortedness

O conceito de **sortedness** busca avaliar a qualidade de projeções em técnicas de RD. Ele mede quão bem a ordem relativa dos pontos é preservada ao passar de um espaço de alta dimensionalidade para um espaço de baixa dimensionalidade. A métrica utiliza o índice de correlação de Kendall τ , conhecido por capturar correlações em dados ranqueados, para avaliar a consistência entre a ordem dos pontos no espaço original e no projetado (Pereira-Santos *et al.*, 2023).

Para um ponto $x \in X$, a **sortedness local** ($\lambda_{\tau w}$) é definida como:

$$\lambda_{\tau w}(x) = \tau_w[r_X(x), r_{\hat{X}}(\hat{x})],$$

aonde:

- $r_X(x)$ é o ranqueamento dos demais pontos com base na proximidade em relação a x no espaço original;
- $r_{\hat{X}}(\hat{x})$ é o ranqueamento no espaço projetado;
- τ_w é o índice de Kendall τ ponderado.

Além disso, a *sortedness global* considera todas as combinações de pares de pontos para avaliar a preservação da estrutura global, útil para medir mudanças em relações de proximidade que vão além do ordenamento de vizinhos (Pereira-Santos *et al.*, 2023).

Os valores de *sortedness* variam entre:


- **1,0**: Projeção perfeita;
- **0,5**: Metade do ordenamento preservado;
- **0,0**: nenhuma correlação;
- **-0,5**: Metade do ordenamento invertido;
- **-1,0**: Ordem completamente invertida.

A Figura 15 apresenta uma visão geral das medidas de avaliação utilizadas para projetar dados de alta dimensionalidade em um espaço reduzido. As medidas variam em sensibilidade a diferentes tipos de transformações e artefatos associados à RD. Medidas como o *stress* métrico (σ_1) capturam pequenas variações, incluindo mudanças irrelevantes, enquanto o *sortedness* local ($\lambda_{\tau w}$) é sensível a alterações na ordem dos vizinhos. Por outro lado, o *pairwise sortedness* ($\Lambda_{\tau 1}$) avalia mudanças nas relações de distância entre pares de pontos, oferecendo uma visão mais ampla da preservação da estrutura global dos dados (Pereira-Santos *et al.*, 2023).

Cada medida captura aspectos específicos da projeção:

- Medida local (λ_{τ_w}): Sensível a mudanças na ordem de vizinhos próximos, sendo ideal para avaliar distorções locais;
- Medida global (Λ_{τ_1}): Penaliza alterações em distâncias relativas entre todos os pares de pontos, refletindo a estrutura global;
- *Stress* métrico (σ_1): Sensível a variações pequenas, incluindo mudanças irrelevantes.

Figura 15 – Medidas de avaliação de projeções em Redução de Dimensionalidade.



Fonte: Adaptado de Pereira-Santos *et al.* (2023).


A Figura 16 apresenta exemplos de transformações em RD, relacionadas a um ponto central. Essas transformações variam do mais trivial ao mais enganoso, destacando:

- Os círculos tracejados em vermelho indicam as posições esperadas para uma transformação exata;
- Linhas em negrito destacam distâncias relevantes para comparação;
- A coloração segue o padrão: vermelho representa os dados originais, azul os dados transformados e cinza as referências.

A Figura 17, por sua vez, mostra o impacto da aleatorização progressiva dos pontos. Inicialmente, os valores de *sortedness* global e local se aproximam de 1, indicando alta preservação da estrutura. No entanto, à medida que mais pontos são randomizados, esses valores tendem a 0, evidenciando a degradação estrutural (Pereira-Santos *et al.*, 2023).


Figura 16 – Transformações de Redução de Dimensionalidade e Seus Efeitos no *Sortedness* em Torno de um Ponto Central

15



Fonte: Adaptado de Pereira-Santos *et al.* (2023).

Figura 17 – Impacto da Aleatorização Progressiva na Estrutura dos Pontos.



Fonte: Pereira-Santos *et al.* (2023).

O *sortedness* oferece uma alternativa robusta e interpretável para avaliar projeções em RD. Suas variantes (local e global) são adequadas para cenários aonde a preservação de estrutura é essencial, seja para visualizações ou para processos em AM (Pereira-Santos *et al.*, 2023).

Tabela 1 – Interpretação dos valores de *stress* segundo (Kruskal, 1964)

Valor de stress	Qualidade da projeção
< 0,05	Excelente
0,05 – 0,10	Boa
0,10 – 0,20	Regular
0,20 – 0,30	Fraca
≥ 0,30	Inaceitável

Fonte: Adaptado de Kruskal (1964).

2.4.7 Stress

A métrica de *stress*, introduzida por Kruskal (1964), desempenha um papel fundamental na avaliação da qualidade das projeções geradas por técnicas de redução de dimensionalidade, especialmente o MDS. Essa métrica quantifica a discrepância entre as distâncias originais, no espaço de alta dimensionalidade, e as distâncias resultantes no espaço reduzido, fornecendo uma medida objetiva de quão bem a estrutura dos dados é preservada (Nordsvan *et al.*, 2020).

A forma mais comum é o *Kruskal's Stress-1*, definido pela Equação 6

$$S = \sqrt{\frac{\sum_{i < j} (d_{ij} - \hat{d}_{ij})^2}{\sum_{i < j} d_{ij}^2}} \quad (6)$$

em que d_{ij} representa a distância original entre os pontos i e j , e $\hat{d}_{ij}$ representa a distância entre esses mesmos pontos no espaço projetado. O valor de S varia entre 0 e 1, sendo que valores mais baixos indicam melhor preservação das relações originais.

A interpretação dos valores de *stress* segue os critérios propostos pelo próprio Kruskal, descritos na Tabela 1.

Embora amplamente utilizada, a métrica de *stress* deve ser interpretada com cautela. Em alguns contextos, valores muito baixos podem indicar sobreajuste (*overfitting*), especialmente quando há aplicação de suavizações excessivas nos dados, como no uso de *Kernel Density Estimation* (KDE). Além disso, a ausência de padronização entre diferentes implementações pode dificultar a comparação direta dos resultados, como destacado por Smelser *et al.* (2024) (Smelser; Miller; Kobourov, 2024).

No presente trabalho, o *stress* foi utilizado tanto para as projeções geradas por t-SNE quanto por MDS, sempre na forma normalizada, conforme fornecida pelas ferramentas computacionais utilizadas. Os valores de *stress* obtidos foram interpretados com base nos limiares definidos por Kruskal, com o propósito de classificar a qualidade das projeções quanto à preservação das distâncias originais.

A métrica de *stress* também encontra aplicação consolidada na geocronologia de zircões detríticos, área na qual o MDS é frequentemente utilizado para reconstrução de padrões sedimentares. Nesses casos, variações nas incertezas de datação podem impactar diretamente os valores de *stress*, especialmente quando matrizes de dissimilaridade são geradas com base

em testes estatísticos como *Kolmogorov-Smirnov* ou *Kuiper*. Diferenças na precisão analítica podem resultar em correlações artificiais, refletindo mais os métodos de análise do que a estrutura real dos dados (Nordsvan *et al.*, 2020).

Adicionalmente, o uso inadequado do *stress* pode levar ao sobreajuste dos dados, comprometendo a generalização do modelo. Esse comportamento é observado quando os valores do *stress* são excessivamente baixos, o que resulta em perda de informações importantes. Tal situação foi identificada no uso do *Kernel Density Estimation (KDE)* no MDS, que, embora suavize os dados, pode reduzir a robustez do modelo e prejudicar a interpretação dos resultados (Nordsvan *et al.*, 2020).

Por outro lado, técnicas como *resampling* e rotação de *Procrustes* foram propostas para mitigar esses problemas. Elas ajustam os dados para que as incertezas das amostras sejam mais uniformes, o que permite um uso mais eficaz da métrica de *stress* para identificar padrões e relações nos dados (Nordsvan *et al.*, 2020). Essas abordagens demonstraram eficácia na melhoria da qualidade das soluções de MDS, reduzindo vieses associados às incertezas de idade (Nordsvan *et al.*, 2020).

Portanto, o *stress* é uma ferramenta crucial para avaliar a qualidade dos resultados do MDS, mas seu uso deve ser combinado com estratégias de validação e ajuste para lidar com as incertezas nos dados, assegurando que os modelos representem com precisão as relações subjacentes nos conjuntos de dados analisados (Nordsvan *et al.*, 2020).

2.5 Escala de Comportamento Adaptativo Vineland

O conceito de comportamento adaptativo refere-se às habilidades necessárias para que um indivíduo atue de forma independente e adequada em seu cotidiano, abrangendo aspectos sociais, comunicativos e práticos (Saulnier; Klaiman; Mcqueen, 2022). Diferente das habilidades cognitivas, que dizem respeito ao potencial de desempenho, o comportamento adaptativo está relacionado ao que a pessoa de fato realiza, sem suporte externo, em resposta às demandas do ambiente (Pepperdine; Mccrimmon, 2017).

A avaliação do comportamento adaptativo é particularmente relevante em populações com transtornos do neurodesenvolvimento, como o Transtorno do Espectro Autista (TEA), em que há frequentemente uma dissociação entre a capacidade cognitiva e o funcionamento adaptativo (Saulnier; Klaiman; Mcqueen, 2022). Nesse contexto, a identificação de déficits adaptativos pode fornecer informações críticas para diagnósticos, planejamento de intervenções e definição de prognóstico.

Historicamente, um dos instrumentos mais amplamente utilizados para essa finalidade é a *Vineland Adaptive Behavior Scales*, criada por Edgar Doll em 1935 sob o nome *Vineland Social Maturity Scale* e posteriormente aprimorada ao longo de diferentes edições (Goldberg *et al.*, 2009). A versão atual, conhecida como Vineland-3, foi publicada em 2016 e mantém o foco original na avaliação do comportamento adaptativo por meio de entrevistas com pais,

cuidadores ou professores, com diferentes formulários disponíveis para cada perfil respondente (Pepperdine; Mccrimmon, 2017).

A Vineland-3 é recomendada tanto para contextos clínicos quanto para pesquisas, sendo uma medida padronizada que permite avaliar o funcionamento adaptativo ao longo do ciclo de vida, desde o nascimento até a vida adulta (Pepperdine; Mccrimmon, 2017). Sua estrutura contempla domínios essenciais como comunicação, habilidades de vida diária e socialização, e tem se mostrado eficaz na identificação de perfis adaptativos em diferentes condições clínicas, como evidenciado em diversos estudos recentes (Wan *et al.*, 2024).

2.5.1 Estrutura e Formatos da Vineland-3

A Vineland-3 foi desenvolvida para avaliar o funcionamento adaptativo de indivíduos entre 0 e 90 anos de idade, oferecendo diferentes formatos de aplicação para se adequar aos variados contextos clínicos e educacionais (Pepperdine; Mccrimmon, 2017). A escala está disponível em três versões principais: *Interview Form*, *Parent/Caregiver Form* e *Teacher Form*. Cada uma dessas formas pode ser aplicada em dois níveis de profundidade: *Comprehensive* (mais detalhado) ou *Domain-Level* (mais conciso), o que permite que o avaliador selecione o formato mais adequado às necessidades da avaliação.

Os três domínios centrais da Vineland-3 — **Comunicação**, **Habilidades de Vida Diária** e **Socialização** — compõem o índice global conhecido como *Adaptive Behavior Composite* (ABC). Um quarto domínio, **Habilidades Motoras**, é opcional e mais comumente utilizado na avaliação de crianças pequenas (Pepperdine; Mccrimmon, 2017; Goldberg *et al.*, 2009). Dentro de cada domínio, existem subdomínios específicos que abrangem áreas funcionais detalhadas. Por exemplo, o domínio de Comunicação inclui os subdomínios de Comunicação Receptiva, Expressiva e Escrita; o de Vida Diária abrange as habilidades pessoais, domésticas e comunitárias; e o de Socialização contempla relações interpessoais, brincadeiras e habilidades de enfrentamento (Pepperdine; Mccrimmon, 2017; Goldberg *et al.*, 2009).

A pontuação da Vineland-3 baseia-se na frequência com que o comportamento é realizado de forma independente. Cada item pode ser pontuado como 0 (nunca), 1 (às vezes) ou 2 (frequentemente ou sempre), com base nos relatos de pessoas que conhecem bem o avaliado, como pais, cuidadores ou professores (Pepperdine; Mccrimmon, 2017). Em versões mais completas, como a *Interview Form*, é utilizada uma entrevista semiestruturada, conduzida por um profissional treinado, que permite explorar com mais profundidade o desempenho do indivíduo em seu contexto diário (Pepperdine; Mccrimmon, 2017).

Além da aplicação em papel, a Vineland-3 também oferece suporte para aplicação digital por meio da plataforma Q-global, que automatiza a seleção de itens com base nas regras de início, basal e teto da escala, otimizando o tempo e reduzindo erros de aplicação (Pepperdine; Mccrimmon, 2017).

A diversidade de formatos torna a Vineland-3 uma ferramenta flexível, apropriada tanto para avaliações clínicas individuais quanto para pesquisas populacionais, sendo frequente-

mente utilizada em estudos com populações com transtornos do neurodesenvolvimento (Wan *et al.*, 2024).

2.5.2 Aspectos Psicométricos e Qualidade Técnica

A Vineland-3 apresenta evidências robustas de qualidade psicométrica, com alta confiabilidade e validade, o que a torna uma ferramenta adequada para contextos clínicos, educacionais e de pesquisa. Os estudos de padronização foram conduzidos com amostras amplas e representativas da população dos Estados Unidos, incluindo indivíduos com e sem deficiências do desenvolvimento (Pepperdine; Mccrimmon, 2017).

A consistência interna da escala é excelente, com coeficientes alfa de Cronbach que variam entre 0,94 e 0,99 para os domínios adaptativos e o índice composto (ABC) nas versões *Comprehensive*, e entre 0,86 e 0,97 nas versões *Domain-Level*. A confiabilidade teste-reteste também se mostrou satisfatória, com correlações corrigidas variando entre 0,62 e 0,94, dependendo do domínio e da versão da escala. Essas análises foram realizadas em intervalos de 12 a 35 dias entre as aplicações, tanto para as formas digitais quanto para as impressas, e os resultados indicaram equivalência entre os formatos (Pepperdine; Mccrimmon, 2017).

Estudos de confiabilidade interavaliadores e entre entrevistadores também foram conduzidos. Os coeficientes corrigidos entre entrevistadores e respondentes mostraram valores que variaram de 0,61 a 0,87, com exceção do domínio de socialização da versão para professores aplicada em crianças de 3 a 5 anos, que apresentou valor inferior (0,46), possivelmente em função da limitação observacional nesse grupo etário (Pepperdine; Mccrimmon, 2017).

Quanto à validade de construto, a estrutura da Vineland-3 baseia-se em três domínios principais — comunicação, socialização e vida diária —, alinhando-se às definições da Associação Americana sobre Deficiências Intelectuais e do Desenvolvimento (AAIDD) e da Associação Psiquiátrica Americana (APA). A análise fatorial confirmou a organização interna da escala, com correlações mais fortes entre subdomínios pertencentes a um mesmo domínio, em comparação com subdomínios de domínios distintos (Pepperdine; Mccrimmon, 2017).

A validade concorrente foi avaliada por meio de correlações entre a Vineland-3 e outras escalas adaptativas, como a *Bayley Scales of Infant and Toddler Development* e a *Adaptive Behavior Assessment System – Third Edition (ABAS-3)*. As correlações foram moderadas a altas, variando de 0,41 a 0,98, dependendo do instrumento, do domínio avaliado e da faixa etária (Pepperdine; Mccrimmon, 2017).

Em estudos transculturais, como na adaptação da Vineland para a população vietnamita, a escala demonstrou boa consistência interna e validade discriminante, sendo capaz de diferenciar significativamente crianças com desenvolvimento típico daquelas com deficiência intelectual (Goldberg *et al.*, 2009).

Assim, os dados psicométricos indicam que a Vineland-3 é uma medida confiável e válida para avaliação de habilidades adaptativas ao longo da vida, com sensibilidade adequada para identificar déficits em diferentes populações clínicas.

2.5.3 Vineland-3 e o Transtorno do Espectro Autista (TEA)

A Vineland-3 tem ampla aplicação na avaliação de indivíduos com TEA, fornecendo informações que complementam a avaliação cognitiva tradicional. Em pessoas com TEA, é comum observar discrepâncias significativas entre o quociente intelectual (QI) e as habilidades adaptativas, especialmente nos domínios de socialização e comunicação, que tendem a ser os mais afetados (Saulnier; Klaiman; Mcqueen, 2022).

Esse padrão de desempenho desproporcional é observado tanto em indivíduos com deficiência intelectual quanto naqueles com inteligência preservada, reforçando a necessidade de avaliar o funcionamento adaptativo de forma independente do QI. Estudos longitudinais também indicam que o progresso nessas habilidades pode ser limitado na adolescência e vida adulta, o que destaca a importância de intervenções precoces e contínuas (Saulnier; Klaiman; Mcqueen, 2022).

2.5.4 Aplicações em Pesquisa e Intervenção

Além de seu uso clínico, a Vineland-3 é amplamente empregada em pesquisas como medida de desfecho funcional. Um exemplo notável é o estudo randomizado e controlado que avaliou o efeito do transplante de microbiota fecal (FMT) em crianças com TEA. Nesse estudo, a Vineland-3 foi utilizada para avaliar mudanças no comportamento adaptativo, com melhora significativa no domínio de socialização entre os participantes do grupo intervenção (Wan *et al.*, 2024).

Outro recurso importante da Vineland-3 em contextos de pesquisa é a métrica *Growth Scale Value* (GSV), que permite detectar mudanças graduais no desempenho adaptativo ao longo do tempo. Esse tipo de medida é especialmente útil em estudos longitudinais e em intervenções que visam promover ganhos funcionais específicos (Pepperdine; Mccrimmon, 2017).

2.6 Trabalhos relacionados

Jaworska e Chupetlovska-Anastasova (2009) descrevem o uso do MDS como uma técnica eficaz para representar graficamente padrões de similaridade em contextos psicológicos. A abordagem é útil especialmente quando os dados são ordinais ou não atendem aos pressupostos de linearidade. Distinguem-se duas variantes principais: métrica e não-métrica, sendo esta última mais empregada em estudos perceptuais e emocionais. O MDS permite explorar estruturas latentes em dados de percepção, cognição, personalidade e neuroimagem, fornecendo representações intuitivas. Ressalta-se, no entanto, que a interpretação das dimensões projetadas é subjetiva e depende do contexto teórico. A escolha da métrica de dissimilaridade e da configuração inicial também impacta significativamente os resultados, exigindo atenção na aplicação prática.

A análise comparativa de técnicas de RD revelou distinções claras entre métodos lineares e não lineares. Abordagens como PCA, *Linear Discriminant Analysis* (LDA) e *Singular Value Decomposition* mostraram-se eficazes em contextos com relações estruturais lineares, sendo aplicadas em tarefas como compressão e discriminação de classes. Em contrapartida, algoritmos não lineares, incluindo *Kernel PCA*, *Locally Linear Embedding* (LLE) e *Isometric Mapping* (ISOMAP), apresentaram melhor desempenho na preservação de topologias complexas, típicas de dados de alta dimensionalidade. A escolha entre essas técnicas depende do grau de linearidade nos dados, sendo recomendada a adoção de métodos não lineares em domínios como bioinformática e reconhecimento de padrões visuais. O estudo também destacou que, apesar do custo computacional mais elevado, os métodos não lineares oferecem representações mais fiéis das relações subjacentes, contribuindo para uma análise mais robusta e interpretável (Suthira; Surendran, 2015).

A revisão das principais técnicas de redução de dimensionalidade em aprendizado de máquina apresenta métodos agrupados em categorias lineares, não lineares e híbridas. Abordagens como PCA, LDA e *Factor Analysis* são indicadas para dados com dependência linear entre atributos, enquanto métodos baseados em grafos, como LLE, *Laplacian Eigenmap* (LE) e ISOMAP, preservam melhor relações não lineares em contextos de alta complexidade. Técnicas híbridas e modelos baseados em aprendizado profundo, como *autoencoders*, conciliam compressão eficiente com maior capacidade de representação. A análise comparativa mostra que a eficácia de cada abordagem depende diretamente da estrutura dos dados e do objetivo analítico, não havendo uma técnica universalmente superior. A escolha do método deve considerar o equilíbrio entre preservação estrutural, interpretabilidade e custo computacional (Velliangiri; Alagumuthukrishnan; Joseph, 2019).

Os métodos não lineares de redução de dimensionalidade, como t-SNE, Kernel Principal Component Analysis (KPCA), LLE, ISOMAP, MDS e LE, foram avaliados quanto à sua capacidade de preservar a estrutura dos dados e otimizar a classificação. t-SNE demonstrou ser altamente eficaz para visualização ao separar padrões complexos, mas apresentou limitações em escalabilidade. KPCA destacou-se na identificação de padrões não lineares, melhorando a acurácia em alguns cenários. LLE e ISOMAP foram eficientes em dados organizados em variedades suaves, mas ISOMAP mostrou instabilidade topológica em alguns casos. MDS e LE preservaram bem as relações locais, mas foram menos eficazes para dados de alta dimensionalidade. Os resultados indicam que a escolha do método depende da distribuição dos dados, com abordagens baseadas em variedades sendo mais indicadas para representações estruturais complexas (Anowar; Sadaoui; Selim, 2021).

A avaliação de técnicas de RD para visualização de dados multidimensionais foi realizada por meio da comparação entre PCA, t-SNE e UMAP. Foram utilizados datasets reais e sintéticos, avaliados por métricas como *trustworthiness*, *continuity* e um novo indicador denominado *sortedness*, baseado no coeficiente de correlação de Kendall. Os resultados mostraram que o t-SNE obteve as melhores projeções visuais, embora com maior custo computacional. O UMAP apresentou desempenho competitivo, aliado à vantagem de maior escalabilidade. Já o

PCA foi o mais eficiente, porém limitado na representação de estruturas não lineares. O uso do *sortedness* permitiu uma análise mais robusta da fidelidade estrutural entre o espaço original e a projeção, evidenciando sua utilidade como métrica complementar às tradicionais (Pereira-Santos *et al.*, 2023).

A confiabilidade (*trustworthiness*) em sistemas de manutenção preditiva (*PdM*) baseados em IA é central para garantir a aceitação e eficácia dessas tecnologias em ambientes industriais. Modelos confiáveis devem oferecer previsões precisas e compreensíveis, o que é abordado através de *XAI* (*Explainable Artificial Intelligence*), que busca melhorar a interpretabilidade e a explicação de decisões tomadas por algoritmos como redes neurais profundas (*LSTM*, *CNN*, *autoencoders*) e métodos clássicos (*SVM*, *Random Forest*). A integração de tecnologias como *IoT*, gêmeos digitais e computação em borda permite o monitoramento em tempo real, aumentando a confiança nas previsões. O artigo destaca ainda a importância de validações robustas em cenários reais e a incorporação de aspectos éticos e transparentes para mitigar riscos e aumentar a aceitação dos sistemas. Confiabilidade é tratada como um elemento crítico para alcançar eficiência, escalabilidade e adoção ampla em indústrias complexas e dinâmicas (Ucar; Karakose; Kırımça, 2024).

Representações multidimensionais inferidas de dados como julgamentos humanos, neuroimagem e redes neurais são fundamentais para capturar estruturas complexas, como hierarquias e relações semânticas. Métodos como PCA, t-SNE, UMAP e *autoencoders* são amplamente utilizados, cada um com vantagens e limitações em termos de compactação, interpretabilidade e desempenho preditivo. Dimensões latentes, embora abstratas, são ferramentas poderosas para modelar regularidades estatísticas e processos cognitivos, permitindo análises profundas de como o cérebro percebe e processa informações. A escolha do método deve equilibrar propriedades como interpretabilidade e eficiência para atender objetivos específicos, reconhecendo as limitações associadas à dependência de dados e algoritmos. Representações bem projetadas podem revelar novos caminhos para entender a cognição humana e suas aplicações práticas (Roads; Love, 2024).

A previsão da resposta a medicamentos contra o câncer foi realizada combinando *embeddings* de genótipos e características químicas de drogas por meio de RNA. Foram utilizados métodos de fusão como concatenação, *tensor product* e mecanismos de atenção, avaliados em diferentes pontos de integração na arquitetura do modelo. Resultados mostraram que métodos de fusão multiplicativa, como *tensor product* parcial, superaram a concatenação em precisão preditiva e eficiência, especialmente ao integrar interações em estágios mais iniciais das representações genéticas. A melhor abordagem conciliou alto desempenho e menor custo computacional. Conclui-se que o uso estratégico de métodos de fusão permite capturar interações gene-droga de maneira mais robusta e biologicamente relevante, aprimorando a interpretação e a previsão de respostas a tratamentos (Nguyen *et al.*, 2024).

Evidências apontam que alterações na microbiota intestinal exercem impacto direto sobre o sistema nervoso central, influenciando comportamentos e respostas emocionais. Estudos indicam que pacientes com distúrbios como depressão, ansiedade e autismo apresentam per-

fis microbianos distintos, com redução na diversidade e aumento de microrganismos potencialmente inflamatórios. Mecanismos envolvidos incluem o eixo microbiota-intestino-cérebro, modulado por vias neurais, endócrinas e imunológicas, além da produção de metabólitos como ácidos graxos de cadeia curta e neurotransmissores. A modulação da microbiota por meio de dieta, prebióticos e probióticos mostrou resultados promissores na atenuação de sintomas neuropsiquiátricos. Essa conexão reforça a importância de investigar a composição microbiana como fator contributivo em transtornos do neurodesenvolvimento e saúde mental (Felice; O'mahony, 2017).

A microbiota intestinal, composta por trilhões de microrganismos, é essencial para a manutenção da saúde humana, influenciando funções digestivas, imunológicas e metabólicas. Fatores genéticos, dietéticos e ambientais moldam o microbioma desde o nascimento, e alterações em sua composição, conhecidas como disbiose, estão associadas a diversas doenças gastrointestinais, como síndrome do intestino irritável Síndrome do Intestino Irritável (SII), doenças inflamatórias intestinais Doenças Inflamatórias Intestinais (DII), doença celíaca e neoplasias. A disbiose reduz a biodiversidade microbiana, promovendo desequilíbrios que podem agravar essas condições. A microbiota também desempenha papel nas doenças metabólicas e no desenvolvimento de câncer colorretal, com terapias que modulam o microbioma, como probióticos e transplante fecal, sendo promissoras tanto para prevenção quanto para tratamento dessas doenças (Passos, 2024).

3 MATERIAIS E MÉTODOS

Esta seção tem como objetivo detalhar os materiais que foram empregados ao longo do desenvolvimento do projeto, abrangendo as configurações de hardware, o ambiente de desenvolvimento selecionado, a linguagem de programação adotada, as bibliotecas utilizadas e os conjuntos de dados empregados.

3.1 Materiais

Ao longo do desenvolvimento deste projeto, foi utilizada a linguagem de programação *Python*, amplamente reconhecida por ser de alto nível, interpretada, dinâmica, multiplataforma e de código aberto. Essa mesma linguagem é amplamente empregada em soluções de IA, AM e *ciência de dados*, destacando-se por sua *sintaxe clara* e seu *vasto ecossistema* de bibliotecas especializadas, como *TensorFlow*, *PyTorch* e *scikit-learn*, que facilitam a implementação de técnicas avançadas de processamento e análise de dados.

Para a geração de gráficos e visualizações, foi utilizados as bibliotecas *Matplotlib* e *Plotly*. A *Matplotlib* é amplamente reconhecida por sua flexibilidade e eficiência na criação de gráficos estáticos de alta qualidade, sendo uma das bibliotecas mais utilizadas para visualização de dados em Python. Por outro lado, a *Plotly* permite a elaboração de visualizações interativas e dinâmicas em duas e três dimensões, sendo especialmente útil para aplicações que requerem interatividade. Além disso, técnicas específicas, como a criação de *embeddings*, serão realizadas com o apoio das funcionalidades oferecidas pela biblioteca *scikit-learn*, que integra algoritmos de aprendizado de máquina e ferramentas de visualização (Pedregosa *et al.*, 2018).

3.1.1 Ambiente de desenvolvimento e ferramentas

O ambiente de desenvolvimento será configurado em um computador pessoal com as seguintes especificações técnicas:

- *Central Processing Unit (CPU)* AMD Ryzen 5 5600G;
- *Graphics Processing Unit (GPU)* Nvidia Geforce 3060 Gigabyte com 12 GB de memória dedicada;
- Memória RAM de 16 GB;
- Armazenamento SSD de 1 TB;
- Sistema Operacional *Windows 11 Home*, versão 23H2.

O *Scikit-learn* é uma biblioteca robusta de aprendizado de máquina em *Python* que oferece uma implementação eficiente do t-SNE, uma técnica de RD não linear projetada para

a visualização de dados de alta dimensão. O t -SNE converte similaridades entre pontos de dados em probabilidades conjuntas e busca minimizar a divergência de *Kullback-Leibler* entre as distribuições de alta e baixa dimensionalidade, preservando, assim, a estrutura local dos dados no espaço de menor dimensão.

É importante notar que a função de custo do t -SNE não é convexa, o que significa que diferentes inicializações podem levar a resultados variados. Por esse motivo, é fundamental ajustar cuidadosamente os hiperparâmetros do t -SNE, como a perplexidade, que está relacionada ao número de vizinhos mais próximos considerados e pode influenciar significativamente os resultados obtidos. O *Scikit-learn* oferece uma interface intuitiva para a aplicação do t -SNE, permitindo a exploração e visualização de estruturas complexas em dados de alta dimensionalidade, sem a necessidade de etapas adicionais de RD (Developers, 2024).

Para garantir um desenvolvimento eficiente e uma análise precisa dos dados, optou-se pelo uso do *Visual Studio Code Insiders* (versão 1.96). Esta é uma versão avançada do editor *Visual Studio Code*, que oferece recursos experimentais, atualizações mais frequentes e integração nativa com extensões voltadas ao desenvolvimento em *Python*. O *Visual Studio Code Insiders* é atualizado diariamente, permitindo acesso antecipado a novos recursos e correções de bugs, o que o torna uma escolha adequada para desenvolvedores que desejam experimentar as últimas funcionalidades. Este editor proporciona funcionalidades como *IntelliSense*, *linting*, depuração integrada e suporte a ambientes virtuais, otimizando o fluxo de trabalho durante o desenvolvimento do projeto (Microsoft, 2024; Pedregosa *et al.*, 2018).

Este ambiente foi fundamental para a realização das análises, testes e implementação do projeto, oferecendo uma infraestrutura robusta e moderna para atender às demandas computacionais necessárias.

3.1.2 Base de dados

Os tempos de coleta analisados neste estudo, denominados $t1$ (tempo 1), $t2$ (tempo 2) e $t4$ (tempo 4), referem-se a diferentes faixas etárias das crianças: $t1$ corresponde ao período de 3 a 6 meses de vida, $t2$ de 6 a 9 meses, e $t4$ de 12 a 15 meses. Todas as bases envolvidas possuem exatamente 251 instâncias e são integradas por meio de um identificador comum, o índice `id_estudo`, que garante a consistência entre os dados microbiológicos e os desfechos analisados.

As informações foram obtidas a partir de tecnologias de sequenciamento avançado, como o *16S rRNA* e o sequenciamento metagenômico, que permitem uma caracterização detalhada da composição microbiana (Naspolini *et al.*, 2024). O *16S rRNA* refere-se ao gene que codifica a subunidade menor do RNA ribossomal, presente em bactérias e arqueias, sendo amplamente utilizado para identificação e classificação taxonômica de microrganismos em amostras ambientais (Janda; Abbott, 2007). Por sua vez, o sequenciamento metagenômico permite a análise de todo o material genético presente nas amostras, possibilitando uma caracterização funcional mais ampla da microbiota (Organization, 2021).

A base utilizada neste trabalho foi construída a partir da sistematização realizada por Napolini *et al.* (2024), em colaboração com o projeto Germina¹, que reuniu informações provenientes de 23 estudos envolvendo crianças de 0 a 3 anos, conduzidos em 11 países: Estados Unidos, China, Itália, Holanda, Finlândia, Áustria, França, Canadá, Espanha e Austrália. Para este trabalho, foi utilizado um subconjunto de dados composto exclusivamente por crianças brasileiras. Os estudos analisados utilizaram escalas validadas para a avaliação de desfechos neurodesenvolvimentais, como cognição, comportamento e desenvolvimento motor (Napolini *et al.*, 2024).

Para condução das análises, os dados foram organizados nos seguintes subconjuntos:

- `df_t1`, `df_t2` e `df_t4`: contêm os dados microbiológicos dos tempos de coleta *t1*, *t2* e *t4*, respectivamente. Cada conjunto possui um número distinto de atributos: `df_t1` possui 79 atributos, `df_t2` possui 118 atributos e `df_t4` possui 178 atributos, refletindo o aumento da diversidade microbiana conforme o avanço da idade das crianças;
- `df_escala_vineland`: contém os escores da escala de comportamento adaptativo Vineland, adotada neste estudo como variável-alvo nas análises de correlação e visualização;
- Atributos de avaliação comportamental, como `ecbq_atf_t4` e `ecbq_ats_t4`, foram excluídos por decisão metodológica, visando manter o foco exclusivo na escala Vineland.

O objetivo principal dessa base de dados é explorar as associações entre a composição do microbioma e os desfechos de neurodesenvolvimento infantil.

De acordo com resultados apresentados na literatura Napolini *et al.* (2024), destacam-se gêneros bacterianos como *Bacteroides*, associado ao desenvolvimento cognitivo e motor, e *Bifidobacterium*, relacionado à positividade emocional e ao desenvolvimento adaptativo. A combinação dessas informações com técnicas de redução de dimensionalidade permite uma análise mais aprofundada dos padrões complexos presentes nos dados microbiológicos, contribuindo de forma significativa para os objetivos deste estudo.


3.2 Métodos

Com o propósito de organizar o fluxo de trabalho do projeto, optou-se por estruturar o conjunto de atividades em oito etapas principais. Essas etapas englobam desde a definição e o preparo das bases de dados, passando pela implementação de uma estratégia de modelagem e o correspondente treinamento, até as fases de avaliação, indução do modelo final, visualização dos resultados e, por fim, análise dos achados obtidos. O fluxograma da Figura 18 ilustra essa

¹ <https://www.projetoagermina.com.br/>

sequência, evidenciando de forma clara o encadeamento das etapas e a abordagem adotada para atingir os objetivos propostos.

Figura 18 – Fluxograma de estudo e organização dos dados



Fonte: Autoria própria (2025).

3.2.1 Primeira etapa: definição de bases de dados

Nesta etapa, foi utilizada uma base de dados consolidada, contendo informações microbiológicas e comportamentais de crianças entre 3 e 15 meses de idade. Essa base inicial foi segmentada em quatro subconjuntos principais, cada um com uma função específica na análise:

- `df_t1`, `df_t2` e `df_t4`: contêm os dados microbiológicos correspondentes aos tempos de coleta *t1* (3 a 6 meses), *t2* (6 a 9 meses) e *t4* (12 a 15 meses), respectivamente;
- `df_escala_vineland`: armazena os scores da escala de comportamento adaptativo Vineland, utilizada como variável-alvo nas análises.

Todos os subconjuntos compartilham a mesma quantidade de instâncias (**251**), integradas por meio do índice `id_estudo`, que garante a vinculação entre os dados microbiológicos e os desfechos comportamentais analisados.

A quantidade de atributos variou entre os conjuntos microbiológicos, refletindo o aumento da diversidade da microbiota com o avanço da idade: `df_t1` possui 79 atributos, `df_t2` possui 118 e `df_t4`, 178 atributos.

Essa estruturação permitiu a condução de análises longitudinais e comparativas do microbioma ao longo do tempo, facilitando a identificação de padrões evolutivos e sua possível associação com o neurodesenvolvimento infantil.

3.2.2 Segunda etapa: tratamento de dados

Nesta etapa, foi realizada uma verificação inicial para avaliar a qualidade e a consistência dos dados. Quando identificadas instâncias com dados faltantes, valores inconsistentes ou ruídos, foram aplicadas estratégias adequadas, como remoção ou imputação, a fim de garantir a integridade do conjunto de dados.

Além disso, foi avaliada a necessidade de aplicar normalização ou padronização das escalas dos atributos, sempre que foi detectada alguma discrepância significativa que pudesse impactar as etapas subsequentes de modelagem.

Por fim, foi conduzida uma análise exploratória preliminar com o objetivo de identificar padrões, anomalias ou redundâncias, documentando-se as decisões tomadas durante o processo de tratamento. Quando não foram detectados problemas significativos, os dados seguiram diretamente para a etapa seguinte.

3.2.3 Terceira etapa: implementação da estratégia de modelagem

Nesta etapa, foi realizada a preparação do experimento, organizando-se a implementação do código necessário para a aplicação das técnicas de redução de dimensionalidade. Inicialmente, foram definidos os parâmetros dos algoritmos e as bibliotecas utilizadas, como *Scikit-learn* e *pandas*.

A estratégia envolveu a estruturação do fluxo de execução do experimento, garantindo a organização e a eficiência do código. Isso incluiu:

- A divisão dos dados em subconjuntos apropriados para teste e validação;
- A aplicação das técnicas de redução de dimensionalidade t-SNE e MDS (na forma métrica), ambas adotadas com igual relevância para a geração dos embeddings;
- A configuração dos hiperparâmetros necessários, como perplexidade, número de iterações e taxa de aprendizado, ajustados às características dos dados.

Foram realizados testes preliminares para assegurar que o ambiente estivesse corretamente configurado e que os modelos funcionassem conforme o esperado. O código foi devidamente documentado com o objetivo de garantir a reprodutibilidade dos experimentos.

3.2.4 Quarta etapa: modelagem do redutor

Nesta etapa, os algoritmos de redução de dimensionalidade, t-SNE e MDS, foram aplicados sobre os dados previamente tratados. O foco principal foi projetar os dados de alta dimensionalidade em espaços bidimensionais e tridimensionais, buscando preservar, na medida do possível, as estruturas locais e globais dos dados originais.

Durante a execução, foram seguidos os seguintes passos:

- Configuração dos parâmetros, como valores de perplexidade, número de iterações, taxa de aprendizado e tipos de distância, ajustados iterativamente;
- Execução do t-SNE sobre os dados tratados para a obtenção de *embeddings* em duas e três dimensões;
- Execução do MDS, com base em matrizes de dissimilaridade previamente calculadas, também gerando projeções em duas e três dimensões;
- Geração de gráficos tridimensionais interativos para visualização dos *embeddings* 3D obtidos;
- Validação preliminar das projeções, com verificação da estabilidade e da qualidade das representações geradas.

Os hiperparâmetros foram ajustados de forma automatizada por meio de laços de repetição, nos quais diferentes combinações de valores foram testadas sistematicamente. Os resultados de cada configuração foram reavaliados, com o objetivo de identificar os parâmetros que proporcionassem projeções mais estáveis, interpretáveis e coerentes com a estrutura dos dados originais.

3.2.5 Quinta etapa: avaliação

Nesta etapa, foi realizada a avaliação da qualidade das projeções obtidas pelos algoritmos t-SNE e MDS. Para isso, foram utilizadas duas métricas complementares: o *sortedness*, descrito na Seção 2.4.6, que avalia a preservação da ordem relativa entre os pontos; e o *stress*, detalhado na Seção 2.4.7, que mensura a discrepância entre as distâncias originais e projetadas. Ambas tiveram como objetivo quantificar a fidelidade estrutural das representações geradas nos espaços de menor dimensionalidade.

As análises seguiram os seguintes critérios:

- **Preservação global:** avaliação da manutenção das distâncias relativas entre pares de pontos;
- **Consistência estrutural:** observação conjunta dos valores de *sortedness* e *stress* em todas as projeções, geradas tanto pelo t-SNE quanto pelo MDS.

Todos os resultados foram documentados, destacando os valores obtidos para cada técnica e métrica, além de indicar possíveis distorções ou perdas de informação. Com base nessas avaliações, foi possível determinar a eficácia de cada algoritmo na preservação da estrutura dos dados nos espaços bidimensional e tridimensional.

É importante destacar que, embora *sortedness* e *stress* sejam métricas complementares na avaliação da qualidade das projeções, uma não implica necessariamente na melhoria da outra. Enquanto o *stress* avalia a preservação das distâncias absolutas entre os pontos no espaço original, o *sortedness* foca na preservação da ordem relativa entre as amostras no espaço reduzido. Dessa forma, ambas oferecem perspectivas distintas e complementares sobre a fidelidade estrutural das representações geradas.

Neste trabalho, a métrica de avaliação adotada para as projeções foi exclusivamente o *sortedness* global, considerando que o *sortedness* local foi abordado apenas no referencial teórico, sem aplicação prática nas análises desenvolvidas.

3.2.6 Sexta etapa: redutor final

Nesta etapa, os modelos finais foram consolidados com base nos resultados obtidos durante o processo de treinamento e avaliação. Tanto o t-SNE quanto o MDS, configurados com seus respectivos parâmetros ideais, foram aplicados de forma definitiva sobre os dados tratados, a fim de gerar as projeções finais em duas e três dimensões.

Foram documentados os seguintes elementos:

- **Parâmetros finais:** valores utilizados no t-SNE, como perplexidade, número de iterações e taxa de aprendizado; e, no caso do MDS, a métrica de distância empregada;
- **Resultados obtidos:** *embeddings* finais produzidos por ambos os algoritmos;
- **Qualidade dos modelos:** valores das métricas de *sortedness* e *stress* com observações sobre a preservação das estruturas locais e globais nas projeções geradas.

Os redutores finais foram então utilizados para apoiar as etapas subsequentes de visualização e análise interpretativa dos dados.

3.2.7 Sétima etapa: visualização

Nesta etapa, os resultados da redução de dimensionalidade foram representados por meio de visualizações bidimensionais e tridimensionais. As projeções obtidas pelos algoritmos

t-SNE e MDS foram convertidas em gráficos e imagens que possibilitaram a interpretação visual dos dados de microbioma infantil.

Foram utilizadas ferramentas como:

- *Matplotlib* e *Plotly* para a geração de gráficos estáticos e interativos;
- Representações que destacaram padrões, agrupamentos e variações nos *embeddings*.

Além dos gráficos em duas dimensões, também foram gerados gráficos tridimensionais interativos, principalmente para as projeções obtidas com o MDS. Estratégias adicionais de visualização, como o uso de cores, foram aplicadas para evidenciar características específicas dos dados. Essas visualizações serviram como suporte à análise interpretativa dos achados obtidos nas etapas seguintes.

3.2.8 Oitava etapa: análise de achados

Por fim, nesta etapa, os resultados obtidos foram analisados detalhadamente com o objetivo de extrair conclusões significativas sobre os padrões e estruturas identificadas nas projeções do microbioma infantil.

Foram abordados os seguintes aspectos:

- **Interpretação dos agrupamentos:** identificação de agrupamentos formados nos *embeddings* e suas possíveis associações com atributos relevantes, como idade ou fatores socioeconômicos;
- **Discussão dos resultados:** comparação com trabalhos relacionados e discussão das justificativas para os padrões observados nas projeções geradas por t-SNE e MDS;
- **Limitações:** análise de possíveis restrições ou distorções associadas aos algoritmos utilizados e às métricas de avaliação aplicadas;
- **Propostas futuras:** sugestões de aprimoramento das estratégias de modelagem ou de novas abordagens analíticas a serem exploradas.

Essa etapa consolidou os principais achados do projeto, apresentando interpretações claras e contextualizadas que contribuíram para o entendimento da evolução do microbioma infantil. As análises finais ofereceram percepções relevantes sobre os padrões presentes nos dados, preparando o terreno para as discussões e conclusões do estudo.

3.3 Execução dos experimentos

Todos os gráficos gerados neste trabalho, incluindo as projeções em 2D e 3D, estão disponíveis no repositório público: https://github.com/jianLicio/TCC_LIVRE. Essa disponibilização visa complementar a análise apresentada, permitindo ao leitor explorar dinamicamente as visualizações e aprofundar a interpretação dos resultados.

3.3.1 Tratamento de dados

Inicialmente, foi realizada a etapa de tratamento de dados, visando garantir a consistência e a integridade das informações utilizadas. Para isso, foi criada uma cópia da base de dados original, denominada `df_microbioma`, a qual serviu como base de trabalho para todas as manipulações subsequentes.

O processo de tratamento incluiu as seguintes ações:

- Verificação da existência de instâncias com valores ausentes;
- Identificação e remoção de colunas com valores constantes (ou seja, atributos cujo valor era idêntico em todas as instâncias);
- Exclusão dos atributos relacionados à idade da criança, mantendo apenas os atributos microbiológicos correspondentes a cada tempo de coleta;
- Segmentação da base `df_microbioma` em quatro conjuntos específicos, unidos pelo índice `id_estudo`:
 - `df_escala_vineland`: contendo exclusivamente o atributo `vin_com_padrao_t4`, relacionado ao escore da escala de comportamento adaptativo Vineland;
 - `df_t1`: contendo todos os atributos prefixados por `t1`, referentes ao tempo de coleta `t1`;
 - `df_t2`: contendo todos os atributos prefixados por `t2`, referentes ao tempo de coleta `t2`;
 - `df_t4`: contendo todos os atributos prefixados por `t4`, referentes ao tempo de coleta `t4`.
- Aplicação de normalização nos conjuntos microbiológicos `df_t1`, `df_t2` e `df_t4`, garantindo a homogeneidade das escalas para as etapas subsequentes.

3.3.2 Implementação da estratégia de modelagem

Com os dados devidamente preparados, foi implementada a estratégia de modelagem computacional. Para isso, foi estruturado um ambiente de desenvolvimento utilizando a linguagem Python e as seguintes bibliotecas:

- **Pandas**: para manipulação de dados tabulares;
- **NumPy**: para operações numéricas e manipulação de matrizes;
- **Scikit-learn**: para aplicação dos algoritmos de redução de dimensionalidade *t-SNE* e *MDS*;
- **Sortedness**: para cálculo da métrica *sortedness*, utilizada na avaliação da qualidade das projeções;
- **Matplotlib**: para geração de gráficos bidimensionais;
- **Plotly**: para criação de gráficos tridimensionais interativos.

Nessa etapa, foram desenvolvidos os scripts responsáveis pela execução dos algoritmos de redução de dimensionalidade, pela avaliação das projeções, bem como pela geração das visualizações dos dados. Todo o código foi organizado de forma modular, visando garantir a reprodutibilidade e a eficiência na condução dos experimentos.

3.3.3 Modelagem dos redutores

Nesta etapa, os algoritmos *t-Distributed Stochastic Neighbor Embedding (t-SNE)* e *Multidimensional Scaling (MDS)* foram aplicados sobre os dados microbiológicos dos três tempos de coleta (`df_t1`, `df_t2` e `df_t4`), tanto em projeções bidimensionais (2D) quanto tridimensionais (3D).

Para ambos os algoritmos, foi conduzido um processo sistemático de ajuste de hiperparâmetros, no qual diversas combinações foram testadas de forma exaustiva. Essa exploração seguiu uma estrutura de validação em duas etapas: uma seleção externa para determinar os melhores parâmetros e uma avaliação interna baseada nas métricas de desempenho adotadas. Entre os parâmetros analisados, destacam-se a métrica de distância, perplexidade, taxa de aprendizado e estado aleatório, conforme o algoritmo considerado. As métricas de distância testadas foram as seguintes:

- Distância Euclidiana (`euclidean`);
- Distância Manhattan (`manhattan`);
- Distância Chebyshev (`chebyshev`);

- Distância Canberra (*canberra*);
- Distância Bray-Curtis (*braycurtis*);
- Distância de Correlação (*correlation*);
- Distância Cosseno (*cosine*);
- Distância Minkowski (*minkowski*).

3.3.3.1 Parâmetros do MDS

O algoritmo *MDS* foi executado para cada métrica de distância, combinada com diferentes valores do parâmetro *random state*². Foi adotado um intervalo inicial de 0 a 1000, com incremento de 50 unidades. Após identificar o melhor valor, foi realizado um refinamento dentro de uma janela de 100 unidades antes e depois do melhor valor, com incremento de 2.

3.3.3.2 Parâmetros do t-SNE

No *t-SNE*, além do *random state*, foram considerados dois hiperparâmetros adicionais: perplexidade e taxa de aprendizado (*learning rate*). A busca iniciou com valores amplos para cada parâmetro:

- **Perplexidade:** 50, 100, 150, 200, 250;
- **Taxa de aprendizado:** 100, 200, 400, 700, 1000;
- **Random state:** intervalo de 0 a 1000, com incremento de 50, seguido de refinamento de 2 em 2 dentro da faixa de 100 unidades ao redor do melhor valor.

Após a seleção preliminar dos melhores valores, cada parâmetro passou por uma etapa de refinamento em torno da configuração considerada ideal. Esse processo foi repetido tanto para as projeções em 2D quanto em 3D.

Esse processo robusto de busca garantiu a seleção dos embeddings que melhor representaram as estruturas dos dados microbiológicos, tanto local quanto globalmente, otimizando a qualidade das projeções para as análises subsequentes.

Os hiperparâmetros testados, bem como seus respectivos intervalos e aplicações, estão resumidos na Tabela 2.

² Pode ser definida como a semente do gerador aleatório

Tabela 2 – Resumo dos hiperparâmetros testados para os algoritmos t-SNE e MDS

Parâmetro	Valores testados	Aplicação
Métricas de distância	Euclidiana, Manhattan, Chebyshev, Canberra, Bray-Curtis, Correlação, Cosseno, Minkowski	Ambos (t-SNE e MDS)
Perplexidade	Inicial: 50, 100, 150, 200, 250. Refinamento: valores próximos ao melhor.	Apenas t-SNE
Taxa de aprendizado	Inicial: 100, 200, 400, 700, 1000. Refinamento: valores próximos ao melhor.	Apenas t-SNE
Random state	Inicial: 0 a 1000 (incremento de 50). Refinamento: melhor-100 a melhor+100 (incremento de 2).	Ambos (t-SNE e MDS)

Fonte: Autoria própria (2025).

4 RESULTADO E DISCUSSÃO

Este capítulo apresenta os principais resultados obtidos por meio da aplicação das técnicas de RD com t-SNE e MDS aos dados do microbioma intestinal infantil. As análises foram conduzidas em espaços bidimensionais e tridimensionais, com o objetivo de explorar padrões estruturais e possíveis associações com escores de comportamento adaptativo. Para cada técnica, foram avaliadas as métricas de *sortedness global* e *stress* de Kruskal, que permitem mensurar a preservação da estrutura dos dados nas projeções. Além disso, são apresentados gráficos que ilustram a organização dos dados embutidos, considerando os diferentes tempos de coleta e os escores da escala Vineland.

4.1 Projeções em 2D

Nesta subseção, são apresentados os resultados das projeções em duas dimensões (2D) obtidas com os algoritmos t-SNE e MDS, para os três tempos de coleta (t1, t2 e t4).

Os gráficos foram gerados a partir da RD calculada para cada tempo. Neste primeiro momento, as amostras são apresentadas com uma coloração única, sem codificação por variáveis externas, com a finalidade de destacar exclusivamente a organização espacial dos pontos no plano projetado. Essa abordagem visa fornecer uma visão clara sobre os padrões estruturais resultantes da redução de dimensionalidade, servindo como base para a análise quantitativa das métricas e a discussão dos resultados obtidos.


4.1.1 Projeções com t-SNE

Representações bidimensionais geradas pelo algoritmo t-SNE estão agrupadas na Figura 19, que exhibe as projeções para os tempos t1 (a), t2 (b) e t4 (c), respectivamente.

Embora visualmente a projeção do tempo t4 não apresente a maior dispersão espacial entre as amostras, os indicadores quantitativos apontam que ela possui a melhor preservação estrutural global. Isso é evidenciado pelo maior valor de *sortedness global* (0,735) e pelo menor valor de *stress* (0,336), refletindo uma projeção mais fiel às relações originais de dissimilaridade entre as amostras.

Em contrapartida, as projeções dos tempos t1 e t2 apresentaram valores inferiores de *sortedness global* (0,328 e 0,278) e valores mais elevados de *stress* (0,378 e 0,477), sugerindo que a organização estrutural global e a preservação das distâncias foram menos eficazes nesses momentos, mesmo que a visualização aparente maior concentração ou agrupamento das amostras.

Observa-se que a projeção do tempo t4 apresenta maior dispersão das amostras no espaço bidimensional, o que indica uma organização estrutural mais definida neste tempo. Esse resultado é coerente com o valor mais elevado de *sortedness global* (0,735) encontrado para t4, que reflete uma melhor preservação da ordem global entre as amostras.

Figura 19 – Projeções com t-SNE 2D

Fonte: Autoria própria (2025).

Tabela 3 – Melhores configurações e métricas para projeções t-SNE 2D

Tempo	Distância	Perplexidade	Taxa de Aprendizado	Sortedness Global	Stress
t1	Cosseno	150	300	0,328	0,378
t2	Euclidiana	50	200	0,278	0,477
t4	Euclidiana	200	700	0,735	0,336

Fonte: Autoria própria (2025).

Em contraste, os tempos t1 e t2 apresentaram agrupamentos mais concentrados, com valores de *sortedness global* de 0,328 e 0,278, respectivamente, indicando menor preservação da estrutura global nesses tempos.

Os valores de *stress* foram relativamente elevados para t1 e t2, sugerindo maior distorção na preservação das distâncias em comparação ao tempo t4, que obteve o menor *stress* (0,336).


A Tabela 3 resume as melhores configurações de hiperparâmetros, assim como as métricas de avaliação para as projeções em 2D utilizando o algoritmo t-SNE.

Esses resultados sugerem que, no contexto dos dados de microbioma intestinal, o tempo t4 apresenta uma estrutura mais bem definida e que o t-SNE foi capaz de capturar essa organização de forma mais eficiente, sobretudo em espaços de maior dispersão, refletindo alterações biológicas mais evidentes neste tempo.

4.1.2 Projeções com MDS

As projeções bidimensionais obtidas com o algoritmo MDS estão reunidas na Figura 20, que apresenta a RD correspondentes aos tempos t1 (a), t2 (b) e t4 (c), respectivamente.

Observa-se que o tempo t4 exibe uma organização estrutural mais definida, com melhor preservação da ordem global e menor distorção na representação das distâncias, conforme indicado pelos valores de *sortedness global* e *stress*. Já os tempos t1 e t2 apresentaram desempenho inferior nessas métricas, com evidências visuais e quantitativas de menor fidelidade estrutural.

Figura 20 – MDS 2D

Fonte: Autoria própria (2025).

Tabela 4 – Métricas de qualidade para projeções MDS 2D

Tempo	Distância	Sortedness Global	Stress (Kruskal)
t1	Cosseno	0,270	0,366
t2	Euclidiana	0,236	0,333
t4	Manhattan	0,746	0,304

Fonte: Autoria própria (2025).

A projeção de t1 apresenta uma configuração próxima de um padrão circular, o que pode ser interpretado como resultado de distorções locais típicas de projeções MDS. Por sua vez, t2 mostra uma distribuição mais compacta e centralizada, que, apesar da aparente uniformidade visual, não reflete uma boa preservação das relações de dissimilaridade.


A Tabela 4 resume os hiperparâmetros e os valores das métricas calculadas para as projeções MDS em 2D.

Esses resultados reforçam que a projeção do tempo t4 apresentou o melhor desempenho na preservação da estrutura global dos dados, refletindo uma organização mais coerente do microbioma nesse momento de coleta.

4.2 Projeções 3D

Nesta subseção, são apresentados os resultados das projeções em três dimensões (3D) obtidas com os algoritmos t-SNE e MDS, para os três tempos de coleta (t1, t2 e t4). As projeções têm como objetivo a representação visual das relações estruturais nos dados de microbioma, reduzindo sua dimensionalidade original de forma a preservar, na medida do possível, a similaridade entre as amostras. Os gráficos foram gerados a partir dos embeddings calculados para cada tempo. Neste primeiro momento, as amostras são apresentadas com uma coloração única, sem codificação por variáveis externas, com a finalidade de destacar exclusivamente a organização espacial dos pontos no plano projetado. Essa abordagem visa fornecer uma visão

Figura 21 – t-SNE 3D



Fonte: Autoria própria (2025).

clara sobre os padrões estruturais resultantes da redução de dimensionalidade, servindo como base para a análise quantitativa das métricas e a discussão dos resultados obtidos.

4.2.1 Projeções com t-SNE 3D

As projeções tridimensionais obtidas com o algoritmo t-SNE estão reunidas na Figura 21, que apresenta os embeddings correspondentes aos tempos t1 (a), t2 (b) e t4 (c), respectivamente.

A inclusão de uma terceira dimensão permite uma visualização mais rica da organização estrutural dos dados, evidenciando padrões espaciais que não são totalmente perceptíveis nas projeções bidimensionais. Nesse contexto, o tempo t2 apresentou o melhor desempenho em termos de *sortedness global* (0,565), indicando uma preservação mais eficaz da ordem entre as amostras.

Apesar de o tempo t4 não ter alcançado o maior valor de *sortedness global*, seus indicadores ainda revelam uma boa fidelidade estrutural (0,480), com um valor de *stress* (0,383) próximo ao dos demais tempos, o que sugere distorções moderadas na projeção tridimensional.

A projeção do tempo t1 obteve desempenho intermediário nas métricas (*sortedness* de 0,443 e *stress* de 0,376), mantendo uma organização estrutural razoável no espaço tridimensional. As diferenças entre os tempos são melhor compreendidas por meio da avaliação conjunta dos indicadores quantitativos e da visualização espacial.

A Tabela 5 apresenta as melhores configurações de hiperparâmetros e as respectivas métricas de qualidade para cada tempo de coleta.

4.2.2 Projeções com MDS 3D


As projeções tridimensionais obtidas com o algoritmo MDS estão apresentadas na Figura 22, correspondentes aos tempos t1 (a), t2 (b) e t4 (c), respectivamente.

Tabela 5 – Melhores configurações e métricas para projeções t-SNE 3D

Tempo	Distância	Perplexidade	Taxa de Aprendizizado	Sortedness Global	Stress
t1	Euclidiana	100	450	0,443	0,376
t2	Euclidiana	50	100	0,565	0,358
t4	Minkowski	50	750	0,480	0,383

Fonte: Autoria própria (2025).

Figura 22 – MDS 3D



Fonte: Autoria própria (2025).

Tabela 6 – Métricas de qualidade para projeções MDS 3D

Tempo	Distância	Random State	Sortedness Global	Stress (Kruskal)
t1	Euclidiana	1210	0,266	0,216
t2	Manhattan	950	0,336	0,230
t4	Manhattan	800	0,749	0,230

Fonte: Autoria própria (2025).

Os resultados indicam que o tempo t4 apresenta a melhor preservação da estrutura global dos dados, com *sortedness global* de 0,749 e *stress* de 0,230, evidenciando uma representação tridimensional altamente fiel às relações de dissimilaridade originais. Esse desempenho se destaca entre os tempos avaliados, tanto em termos quantitativos quanto na distribuição espacial observada.

As projeções dos tempos t1 e t2, embora com valores inferiores de *sortedness global* (0,266 e 0,336, respectivamente), também mantiveram baixos níveis de *stress* (0,216 e 0,230), o que indica que, apesar de uma menor preservação da ordem global, houve uma distorção relativamente pequena nas distâncias representadas. Esses resultados reforçam a efetividade do MDS na geração de projeções tridimensionais coerentes, mesmo nos tempos com desempenho intermediário.

A Tabela 6 apresenta os melhores hiperparâmetros e as métricas de qualidade obtidas para cada tempo de coleta.




Figura 23 – Projeções t-SNE 2D com todas as amostras (classificação por desvio padrão)
Fonte: Autoria própria (2025).

4.3 Projeções 2D com Classificação por Desvio Padrão

Nesta subseção será apresentado as projeções em 2D pelos métodos t-SNE e MDS usando a escala de Vineland para a métrica do desvio padrão.

4.3.1 Projeções t-SNE 2D com Classificação por Desvio Padrão

Nesta seção, são apresentados os resultados das projeções bidimensionais geradas com o algoritmo t-SNE, aplicadas aos dados de microbioma infantil nos tempos de coleta t1, t2 e t4. As visualizações incorporam a classificação dos participantes conforme a escala Vineland, segmentada por desvio padrão em três categorias: abaixo (vermelho), dentro (cinza) e acima (azul).

Foram geradas duas versões de visualização: uma completa, que inclui todas as amostras (incluindo aquelas dentro do padrão), e outra focada apenas nos grupos extremos, aonde as amostras classificadas como dentro do padrão foram removidas. Essa abordagem permite uma análise mais clara da separação entre os grupos com desenvolvimento atípico.

Tempo t1: Com métrica cosseno, perplexidade 150, taxa de aprendizado 300 e *random state* 1000, obteve-se *sortedness global* de 0,328 e *stress* de 0,378. A projeção resultante apresenta organização centralizada e dispersão moderada entre os grupos.

Tempo t2: Utilizando métrica euclidiana, perplexidade 50, taxa de aprendizado 200 e *random state* 530, foram obtidos *sortedness global* de 0,278 e *stress* de 0,477. A estrutura apresenta relativa compactação, com indícios de separação parcial entre os grupos extremos.

Tempo t4: Com métrica *squeuclidean*, perplexidade 200, taxa de aprendizado 700 e *random state* 0, o tempo t4 apresentou o melhor desempenho estrutural, com *sortedness global* de 0,735 e *stress* de 0,336. A visualização revela uma separação mais clara entre os grupos abaixo e acima do desvio padrão.




Figura 24 – Projeções t-SNE 2D com amostras extremas (sem grupo dentro do padrão)
Fonte: Autoria própria (2025).

Essas visualizações auxiliam na compreensão de como os grupos classificados por desvio padrão na escala Vineland se distribuem no espaço bidimensional gerado pelo t-SNE, contribuindo para a análise de possíveis relações entre o microbioma e o desenvolvimento infantil.

4.3.2 MDS 2D com Classificação por Desvio Padrão

Nesta subseção são apresentados os resultados das projeções bidimensionais (2D) geradas com o algoritmo MDS, aplicadas aos dados de microbioma infantil nos tempos de coleta t1, t2 e t4. As projeções têm como objetivo representar visualmente as relações estruturais dos dados em associação com a escala de desenvolvimento infantil Vineland, cuja classificação é feita com base no desvio padrão: abaixo (vermelho), dentro (cinza) e acima (azul).

Assim como na análise com t-SNE, foram geradas duas visualizações para cada tempo: uma completa, contendo todas as amostras, e outra incompleta, na qual as amostras classificadas como dentro do padrão foram removidas, permitindo uma análise mais clara das extremidades.

Tempo t1: Utilizando a métrica cosseno e *random state* 1180, foram obtidos *sortedness global* de 0,270 e *stress* de 0,366. A projeção apresenta uma distribuição relativamente centralizada, sem separações bem definidas entre os grupos extremos.

Tempo t2: Com a métrica euclidiana e *random state* 72, o valor de *sortedness global* foi de 0,236 e o *stress* de 0,333. A projeção demonstra maior dispersão em comparação ao tempo t1, com leve indício de separação entre os grupos extremos, mais evidente na visualização com as amostras cinza ocultadas.

Tempo t4: Utilizando a métrica *Manhattan* e *random state* 950, obteve-se *sortedness global* de 0,746 e *stress* de 0,304, indicando a projeção com melhor desempenho estrutural entre os tempos avaliados. Observa-se uma separação mais clara entre os grupos abaixo e acima do desvio padrão.




Figura 25 – Projeções MDS 2D com todas as amostras (classificação por desvio padrão)

Fonte: Autoria própria (2025).




Figura 26 – Projeções MDS 2D com amostras extremas (sem grupo dentro do padrão)

Fonte: Autoria própria (2025).

Essas visualizações permitem investigar como os grupos com desenvolvimento atípico se organizam no espaço bidimensional gerado pelo MDS, facilitando a interpretação de possíveis padrões associados ao desenvolvimento infantil.

4.4 Projeções 3D com Desvio Padrão

Nesta subseção será apresentado as projeções em 3D pelos métodos t-SNE e MDS usando a escala de Vineland para a métrica do desvio padrão.

4.4.1 Projeções t-SNE 3D com Classificação por Desvio Padrão

Aqui são apresentados os resultados das projeções tridimensionais (3D) realizadas com o algoritmo t-SNE, aplicadas aos dados de microbioma infantil para os tempos de coleta t1, t2 e t4. As projeções têm o objetivo de visualizar as relações estruturais dos dados e sua associação com a escala de desenvolvimento infantil Vineland, classificada em três categorias conforme o desvio padrão: abaixo (vermelho), dentro (cinza) e acima (azul).




Figura 27 – t-SNE 3D com todas as categorias: abaixo (vermelho), dentro (cinza) e acima (azul) do desvio padrão. (a) t4, (b) t1, (c) t2.

Fonte: Autoria própria (2025).

Cada tempo possui duas visualizações: uma completa, exibindo todas as amostras, e outra incompleta, na qual foram removidos os pontos dentro do padrão (cinza), com o intuito de facilitar a observação dos extremos.

Tempo t1: Utilizando a métrica Euclidiana, perplexidade 100, taxa de aprendizado 450 e *random state* 1075, obteve-se sortedness global de 0,443283 e stress de 0,375557. As Figuras 27(b) e 28(b) mostram uma projeção com dispersão moderada dos pontos, sem evidência clara de separação entre as categorias.

Tempo t2: Com a métrica Euclidiana, perplexidade 50, taxa de aprendizado 100 e *random state* 875, foi obtido o maior valor de sortedness global (0,565242) e stress de 0,357752. Conforme observado nas Figuras 27(c) e 28(c), os pontos se distribuem de forma ampla, mas sem padrões de segmentação evidentes entre os grupos extremos.

Tempo t4: Utilizando a métrica Minkowski, perplexidade 50, taxa de aprendizado 750 e *random state* 120, obteve-se sortedness global de 0,480065 e stress de 0,382601. As Figuras 27(a) e 28(a) mostram uma configuração tridimensional semelhante aos outros tempos, com distribuição difusa das amostras.

De modo geral, as projeções 3D obtidas com t-SNE não revelam formações evidentes de agrupamentos entre as categorias da escala Vineland, mas fornecem uma base útil para análise exploratória e comparação entre os diferentes tempos de coleta.

4.4.2 MDS 3D com Classificação por Desvio Padrão

Aqui são apresentados os resultados das projeções tridimensionais (3D) realizadas com o algoritmo MDS, aplicadas aos dados de microbioma infantil para os tempos de coleta t1, t2 e t4. Assim como foi feito para o t-SNE, as projeções buscam representar visualmente as relações estruturais dos dados, associando-as com a classificação na escala de desenvolvimento infantil Vineland, categorizada em: abaixo (vermelho), dentro (cinza) e acima (azul) do desvio padrão.




Figura 28 – t-SNE 3D com apenas os grupos extremos: abaixo (vermelho) e acima (azul) do desvio padrão. (a) t4, (b) t1, (c) t2.

Fonte: Autoria própria (2025).

Cada tempo está representado em dois gráficos: um completo, contendo todas as amostras, e outro incompleto, no qual os pontos dentro do padrão (cinza) foram removidos, permitindo uma visualização mais clara dos grupos extremos.

Tempo t1: Utilizando a métrica Euclidiana e *random state* 1210, obteve-se sortedness global de 0,266017 e stress de 0,215526. A visualização apresenta os pontos distribuídos de forma densa e relativamente concentrada, sem evidências visuais claras de separação entre os grupos.

Tempo t2: Com a métrica *Manhattan* e *random state* 950, o modelo apresentou sortedness global de 0,336003 e stress de 0,229507. A distribuição dos pontos mostra uma dispersão levemente maior em relação ao tempo t1, mas ainda sem indicações de distinções evidentes entre as categorias.

Tempo t4: Aplicando também a métrica *Manhattan*, com *random state* 800, foi obtido o maior valor de sortedness global (0,749208) entre os tempos analisados, além de stress de 0,230448. Esses indicadores apontam para uma preservação mais eficaz das relações de dissimilaridade no espaço tridimensional. No entanto, mesmo com melhor desempenho quantitativo, não se observam separações visuais bem definidas entre os grupos nas projeções.

As projeções completas e incompletas para os três tempos estão apresentadas, respectivamente, nas Figuras 29 e 30.

Essas visualizações tridimensionais podem ser exploradas de forma interativa por meio de uma ferramenta online disponível no repositório GitHub do autor¹. Nessa plataforma, é possível alternar a visibilidade das categorias e rotacionar os gráficos, contribuindo para uma análise mais precisa da organização espacial e das possíveis relações entre o microbioma intestinal e os desfechos de desenvolvimento infantil.

É importante destacar que, embora sortedness e stress sejam métricas complementares, uma não implica necessariamente na melhoria da outra. Enquanto o stress avalia a preser-

¹ Disponível em: https://github.com/jianLicio/TCC_LIVRE




Figura 29 – MDS 3D Completo
Fonte: Autoria própria (2025).




Figura 30 – MDS 3D Incompleto
Fonte: Autoria própria (2025).

vação das distâncias absolutas entre os pontos, o sortedness foca na preservação da ordem relativa das amostras no espaço reduzido.

5 CONSIDERAÇÕES FINAIS

Este trabalho teve como objetivo principal a aplicação, avaliação e comparação de técnicas de RD aplicadas a dados de microbioma infantil, utilizando os métodos t-SNE e MDS. As projeções foram analisadas com base em dois critérios principais: *sortedness global*, que avalia a preservação da ordem relativa entre as amostras, e o *stress de Kruskal*, que mensura a distorção global das distâncias após a redução de dimensionalidade.

É importante destacar que essas métricas são complementares, porém independentes. Enquanto o *stress* busca preservar a proporcionalidade das distâncias originais, o *sortedness* se concentra na manutenção da hierarquia relacional entre os pontos. Dessa forma, um bom desempenho em uma métrica não garante necessariamente um bom resultado na outra, tornando essencial a análise conjunta para uma avaliação rigorosa da qualidade das projeções.

Os experimentos demonstraram que não existe uma configuração universalmente superior para todos os tempos de coleta, nem um método que se destaque em todos os cenários. A qualidade dos *embeddings* variou conforme a combinação entre tempo, métrica de distância, número de dimensões e o método utilizado (t-SNE ou MDS).

5.1 Conclusão

A partir dos resultados obtidos, foi possível selecionar os melhores *embeddings* para cada tempo de coleta, considerando os critérios de *sortedness* e *stress*. A seguir, são destacados os melhores resultados:

- **Tempo t1:** O melhor resultado em 2D foi obtido com o t-SNE utilizando a distância cosseno, perplexidade 150 e taxa de aprendizado 300, apresentando *sortedness global* de 0,328 e *stress* de 0,377. Para 3D, o t-SNE com distância euclidiana, perplexidade 100 e taxa de aprendizado 450 obteve *sortedness global* de 0,443 e *stress* de 0,375. No caso do MDS, os melhores resultados foram com distância cosseno em 2D (*sortedness* 0,270, *stress* 0,366) e distância euclidiana em 3D (*sortedness* 0,266, *stress* 0,215).
- **Tempo t2:** No t-SNE 2D, o melhor *embedding* foi obtido com distância euclidiana, perplexidade 50 e taxa de aprendizado 200, atingindo *sortedness global* de 0,278 e *stress* de 0,477. Para 3D, o melhor resultado foi com distância euclidiana, perplexidade 50 e taxa de aprendizado 100, apresentando *sortedness global* de 0,565 e *stress* de 0,358. No MDS, os melhores resultados foram utilizando distância euclidiana em 2D (*sortedness* 0,236, *stress* 0,333) e distância Manhattan em 3D (*sortedness* 0,336, *stress* 0,230).
- **Tempo t4:** No t-SNE 2D, o melhor desempenho foi obtido com distância euclidiana, perplexidade 200 e taxa 700, resultando em *sortedness* 0,735 e *stress* 0,336. Na projeção 3D, o melhor resultado foi com distância Minkowski, perplexidade 50 e taxa 750,

Tabela 7 – Resultado de projeções por tempo, método, dimensão e métrica de distância

Tempo	Método	Dimensão	Distância	Sortedness	Stress
t1	t-SNE	2D	Cosseno	0,328	0,377
t1	t-SNE	3D	Euclidiana	0,443	0,376
t1	MDS	2D	Cosseno	0,270	0,366
t1	MDS	3D	Euclidiana	0,266	0,216
t2	t-SNE	2D	Euclidiana	0,278	0,477
t2	t-SNE	3D	Euclidiana	0,565	0,358
t2	MDS	2D	Euclidiana	0,236	0,333
t2	MDS	3D	Manhattan	0,336	0,230
t4	t-SNE	2D	Euclidiana	0,735	0,336
t4	t-SNE	3D	Minkowski	0,480	0,383
t4	MDS	2D	Manhattan	0,746	0,304
t4	MDS	3D	Manhattan	0,749	0,230

Fonte: Autoria própria (2025).

Tabela 8 – Melhor projeção por tempo de coleta considerando o maior valor de *sortedness global*

Tempo	Método	Dimensão	Distância	Sortedness	Stress
t1	t-SNE	3D	Euclidiana	0,443	0,376
t2	t-SNE	3D	Euclidiana	0,565	0,358
t4	MDS	3D	Manhattan	0,749	0,230

Fonte: Autoria própria (2025).

apresentando *sortedness* 0,480 e *stress* 0,383. Para o MDS, a melhor performance foi com distância Manhattan, tanto em 2D (*sortedness* 0,746, *stress* 0,304) quanto em 3D (*sortedness* 0,749, *stress* 0,230).

Na Tabela 7 são apresentados os melhores resultados obtidos para cada tempo de coleta, considerando as diferentes combinações de método, dimensionalidade e distância. Essa tabela consolida os valores de *sortedness global* e *stress de Kruskal* que foram alcançados nas projeções em duas e três dimensões, tanto para o t-SNE quanto para o MDS. Essa visão permite uma análise comparativa abrangente, evidenciando como o desempenho dos métodos varia conforme o tempo de coleta e os parâmetros adotados

A Tabela 8 sintetiza as melhores projeções obtidas para cada tempo de coleta, levando em consideração exclusivamente o maior valor de *sortedness global*. Essa seleção reflete as configurações que proporcionaram a melhor preservação da ordem estrutural dos dados no espaço reduzido, sendo, portanto, as mais indicadas para interpretações visuais e análises subsequentes. Observa-se que, enquanto para os tempos t1 e t2 o método t-SNE tridimensional foi o que obteve melhor desempenho, para o tempo t4 o método MDS tridimensional apresentou o maior valor absoluto de *sortedness global*.

Além dos resultados quantitativos, destaca-se que estudos na literatura apontam uma relação relevante entre a composição do microbioma infantil e o desenvolvimento cognitivo e comportamental, avaliado por instrumentos como a Vineland-3. Carlson *et al.* (2018) analisaram amostras fecais em 89 crianças e encontraram associações significativas entre a diversidade e agrupamentos microbianos aos 12 meses e o desempenho cognitivo medido aos 2 anos

de idade. Essas evidências reforçam o potencial da integração entre projeções estruturais do microbioma, como as analisadas neste trabalho, e escores adaptativos para elucidar como a maturação microbiana pode refletir – ou impactar – processos de desenvolvimento infantil.

De forma geral, observa-se que o tempo t4 apresentou os maiores valores de *sortedness global*, independentemente do método e da dimensionalidade. Esse resultado sugere que, nesse estágio, o microbioma infantil possui uma organização estrutural mais definida, reflexo de um processo natural de estabilização biológica associado à maturação fisiológica e imunológica das crianças. Essa maior maturidade se traduz na formação de padrões mais bem delineados nas projeções, facilitando a identificação de agrupamentos e tornando o tempo t4 especialmente relevante para análises, classificações e estudos que buscam compreender as associações entre o microbioma e o desenvolvimento infantil.

5.2 Trabalhos Futuros

Os resultados obtidos neste estudo mostram que, conforme a criança cresce, a qualidade das projeções melhora progressivamente. Esse efeito está diretamente relacionado ao aumento da diversidade e maturidade do microbioma, que se torna mais estruturado, complexo e informativo com o avanço da idade. Diante desse comportamento, propõe-se como trabalho futuro a exploração de um possível tempo de coleta t5, correspondente a uma faixa etária ainda mais avançada — posterior ao tempo t4.

A inclusão desse novo tempo tem o potencial de fornecer projeções com qualidade estrutural superior, uma vez que o microbioma, nesse estágio, tende a estar mais consolidado, refletindo uma maior estabilidade e maturidade biológica. Isso pode contribuir não apenas para gerar *embeddings* mais precisos, mas também para aprofundar a compreensão sobre a evolução do microbioma infantil e sua relação com os desfechos comportamentais e de desenvolvimento. Avaliar esse tempo t5 poderá responder se a tendência de melhoria na qualidade das projeções se mantém ou se estabiliza a partir de certo ponto do desenvolvimento.

Além disso, com base nos melhores *embeddings* obtidos neste estudo, abre-se a possibilidade de realizar análises interpretativas mais avançadas. Uma abordagem promissora consiste na utilização do método *SHAP Values* (*SHapley Additive exPlanations*), que permite interpretar modelos preditivos de maneira consistente, fundamentada na teoria dos jogos.

Por meio do SHAP, seria possível quantificar a contribuição de cada variável — no caso, cada espécie bacteriana — na formação dos padrões estruturais observados nas projeções. Isso permitiria identificar quais bactérias são mais relevantes para a organização dos dados em cada tempo de coleta, inclusive no potencial t5, promovendo uma compreensão biológica ainda mais detalhada dos agrupamentos detectados.

Essa estratégia não apenas complementa as análises estruturais realizadas neste trabalho, como também abre caminho para investigações direcionadas na microbiologia, permitindo associar grupos bacterianos específicos a padrões de desenvolvimento infantil ou outros desfechos clínicos. Além disso, a utilização do SHAP poderá auxiliar na construção de modelos

preditivos mais robustos, transparentes e explicáveis, com aplicações potenciais em diagnóstico, monitoramento e intervenções clínicas.

REFERÊNCIAS

- ANOWAR, F.; SADAoui, S.; SELIM, B. Conceptual and empirical comparison of dimensionality reduction algorithms (pca, kpca, lda, mds, svd, lle, isomap, le, ica, t-sne). **Computer Science Review**, Elsevier v. 40., p. 100378, 2021. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S1574013721000186>. Acesso em: 15 mar. 2025.
- ARTERO, A. O. **Inteligência Artificial: Teórica e Prática**. 1. ed. São Paulo, Brasil: Livraria da Física, 2008. 230 p. ISBN 9788578610296. Disponível em: <https://biblioteca.utfpr.edu.br/acervo/247156>. Acesso em: 09 dez. 2024.
- BISHOP, C. M. E-book. **Pattern Recognition and Machine Learning**. 1. ed. New York: Springer, 2006. 676 p. ISBN 978-0387310732. Disponível em: <https://www.microsoft.com/en-us/research/uploads/prod/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>. Acesso em: 09 dez. 2024.
- CARLSON, A. L. *et al.* Infant gut microbiome associated with cognitive development. **Biological psychiatry**, Elsevier v. 83, n. 2, p. 148–159, 2018. Disponível em: https://www.sciencedirect.com/science/article/abs/pii/S0006322317317201?fr=RR-2&ref=pdf_download&rr=9556e154a9b75d23. Acesso em: 24 jun. 2025.
- CARROLL, L. Alice's adventures in wonderland. In: **Alice's Adventures in Wonderland**. London: Macmillan, 1865. p. Chapter 10. Tradução livre da frase: “Não posso voltar para ontem, porque eu era uma pessoa diferente naquela época.”. Disponível em: https://en.wikisource.org/wiki/Page%3ALewis_Carroll_-_Alice%27s_Adventures_in_Wonderland.djvu/175?utm_source=chatgpt.com. Acesso em: 20 mar. 2025.
- DEVELOPERS, S. learn. **sklearn.manifold.TSNE - Scikit-learn Documentation**. [S.l.]: , 2024. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.manifold.TSNE.html>. Acesso em: 09 dez. 2024.
- FAINTUCH, J. E-book. **Microbioma, disbiose, probióticos e bacterioterapia**. Barueri: Manole, 2017. 34 p. ISBN 9788520462362. Disponível em: <https://app.minhabiblioteca.com.br/reader/books/9788520462362>. Acesso em: 02 dez. 2024.
- FAYYAD, U.; PIATETSKY-SHAPIO, G.; SMYTH, P. From data mining to knowledge discovery in databases. **AI Magazine**, American Association for Artificial Intelligence v. 17, n. 3, p. 37–54, 1996. Disponível em: <https://ojs.aaai.org/aimagazine/index.php/aimagazine/article/view/1230>. Acesso em: 09 dez. 2024.
- FELICE, V. D.; O'MAHONY, S. M. The microbiome and disorders of the central nervous system. **Pharmacology Biochemistry and Behavior**, Elsevier v. 160., p. 1–13, 2017. Disponível em: [sciencedirect.com/science/article/pii/S0091305717300242](https://www.sciencedirect.com/science/article/pii/S0091305717300242). Acesso em: 09 dez. 2024.
- GHOJOGH, B. *et al.* Multidimensional scaling, sammon mapping, and isomap: Tutorial and survey. **arXiv preprint arXiv:2009.08136**, , 2020. Disponível em: <https://arxiv.org/abs/2009.08136>. Acesso em: 15 mar. 2025.
- GOLDBERG, M. R. *et al.* Reliability and validity of the vietnamese vineland adaptive behavior scales with preschool-age children. **Research in Developmental Disabilities**, Elsevier v. 30, n. 3, p. 592–602, 2009. Disponível em: https://www.sciencedirect.com/science/article/pii/S0891422208001145?casa_token=

7CiOc6XG8V4AAAAA:7QyAf7DQvurYTOm56K-BI81AF2wR6daBzMizKgaAmCAw1fRj80pa_gKYIRxmP9qldyEhW_cq. Acesso em: 17 mar. 2025.

HAYKIN, S. E-book. **Redes Neurais: Princípios e Prática**. 2. ed. Porto Alegre: Bookman, 2007. 28 p. ISBN 9788577800865. Disponível em: <https://integrada.minhabiblioteca.com.br/reader/books/9788577800865>. Acesso em: 02 dez. 2024.

JANDA, J. M.; ABBOTT, S. L. 16s rRNA gene sequencing for bacterial identification in the diagnostic laboratory: pluses, perils, and pitfalls. **Journal of clinical microbiology**, Am Soc Microbiol v. 45, n. 9, p. 2761–2764, 2007. Disponível em: <https://journals.asm.org/doi/full/10.1128/jcm.01228-07>. Acesso em: 19 fev. 2025.

JAWORSKA, N.; CHUPETLOVSKA-ANASTASOVA, A. A review of multidimensional scaling (mds) and its utility in various psychological domains. **Tutorials in Quantitative Methods for Psychology**, University of Ottawa v. 5, n. 1, p. 1–10, 2009. Disponível em: <https://mail.tqmp.org/RegularArticles/vol05-1/p001/p001.pdf>. Acesso em: 09 dez. 2024.

KRUSKAL, J. B. Multidimensional scaling by optimizing goodness of fit to a nonmetric hypothesis. **Psychometrika**, v. 29, n. 1, p. 1–27, 1964. Disponível em: http://cda.psych.uiuc.edu/psychometrika_highly_cited_articles/kruskal_1964a.pdf. Acesso em: 17 mar. 2025.

LIMA, I.; PINHEIRO, C. A. M.; OLIVEIRA, F. A. **Inteligência Artificial**. 1. ed. Rio de Janeiro, Brasil: Campus, 2014. 173 p. ISBN 9788535278088. Disponível em: <https://biblioteca.utfpr.edu.br/acervo/275291>. Acesso em: 09 dez. 2024.

LOPES, M. A. d. S. t-sne paralelo: uma técnica paralela para redução de dimensionalidade de dados aplicada em cidades inteligentes, . Universidade Federal do Rio Grande do Norte,, 2020. Disponível em: repositorio.ufrn.br/bitstream/123456789/31522/1/tSNEparalelotecnica_Lopes_2020.pdf. Acesso em: 09 dez. 2024.

LUDERMIR, T. B. Inteligência artificial e aprendizado de máquina: estado atual e tendências. **Estudos Avançados**, SciELO Brasil v. 35, p. 85–94, 2021. Disponível em: www.scielo.br/j/ea/a/wXBdv8yHBV9xHz8qG5RCgZd/?lang=pt&format=html. Acesso em: 09 dez. 2024.

MAATEN, L. Van der; HINTON, G. Visualizing data using t-sne. **Journal of machine learning research**, v. 9, n. 11,, 2008. Disponível em: jmlr.org/papers/volume9/vandemaaten08a/vandemaaten08a.pdf?fbcl. Acesso em: 09 dez. 2024.

MICROSOFT. **Visual Studio Code Insiders**. [S.l.]: , 2024. Disponível em: <https://code.visualstudio.com/docs/languages/python>. Acesso em: 16 mai. 2025.

NASPOLINI, N. F. *et al.* The gut microbiome in the first one thousand days of neurodevelopment: A systematic review from the microbiome perspective. **Microorganisms**, MDPI v. 12, n. 3, p. 424, 2024. Disponível em: <https://www.mdpi.com/2076-2607/12/3/424>. Acesso em: 19 fev. 2025.

NGUYEN, T. *et al.* Optimal fusion of genotype and drug embeddings in predicting cancer drug response. **Briefings in Bioinformatics**, Oxford University Press v. 25, n. 3, p. bbae227, 2024. Disponível em: <https://doi.org/10.1093/bib/bbac227>. Acesso em: 09 dez. 2024.

NORDSVAN, A. R. *et al.* Resampling (detrital) zircon age distributions for accurate multidimensional scaling solutions. **Earth-Science Reviews**, Elsevier v. 204,, p. 103149, 2020. Disponível em: <https://doi.org/10.1016/j.earscirev.2020.103149>. Acesso em: 09 dez. 2024.

ORGANIZATION, P. A. H. **Sequenciamento metagenômico: Guia técnico para a América Latina e o Caribe**. [S.l.], 2021. Disponível em: <https://iris.paho.org/handle/10665.2/54312>. Acesso em: 19 fev. 2025.

- PASSOS, M. d. C. F. Importância do microbioma intestinal em gastroenterologia. **Medicina, Ciência e Arte**, v. 3, n. 1, p. 7–18, 2024. Disponível em: medicinacienciaearte.emnuvens.com.br/revista/article/view/73/68. Acesso em: 09 dez. 2024.
- PEDREGOSA, F. *et al.* **Scikit-learn: Machine Learning in Python**. [S.l.]: , 2018. Disponível em: <https://arxiv.org/abs/1201.0490>. Acesso em: 15 mar. 2025.
- PEPPERDINE, C. R.; MCCRIMMON, A. W. Vineland adaptive behavior scales, third edition. **Canadian Journal of School Psychology**, v. 32, n. 4, p. 313–317, 2017. Disponível em: https://crossmark.crossref.org/dialog/?doi=10.1177%2F0829573517733845&domain=pdf&date_stamp=2017-09-29. Acesso em: 17 mar. 2025.
- Pereira-Santos, D. *et al.* Nonparametric dimensionality reduction quality assessment based on sortedness of unrestricted neighborhood. *In*: PROCEEDINGS. 2023. **Anais [...]** [s.n.], 2023. Disponível em: <https://repositorio.usp.br/directbitstream/2597794c-2c0f-4c32-8dce-db5b8496a08a/3172748.pdf>. Acesso em: 09 dez. 2024.
- ROADS, B. D.; LOVE, B. C. The dimensions of dimensionality. **Trends in Cognitive Sciences**, Elsevier,, 2024. Disponível em: [https://cell.com/action/showPdf?pii=S1364-6613\(24\)00189-X](https://cell.com/action/showPdf?pii=S1364-6613(24)00189-X). Acesso em: 09 dez. 2024.
- RUSSELL, S. J.; NORVIG, P. **Inteligência Artificial**. 3. ed. Rio de Janeiro, Brasil: Elsevier, 2013. 988 p. ISBN 9788535237016. Disponível em: <https://biblioteca.utfpr.edu.br/acervo/265488>. Acesso em: 14 fev. 2025.
- SAULNIER, C. A.; KLAIMAN, C.; MCQUEEN, E. Adaptive behavior profiles in autism spectrum disorder. **Current Psychiatry Reports**, Springer v. 24, n. 12, p. 749–756, 2022. Disponível em: <https://link.springer.com/article/10.1007/s11920-022-01381-w>. Acesso em: 17 mar. 2025.
- SMELSER, K.; MILLER, J.; KOBOUROV, S. “normalized stress” is not normalized: How to interpret stress correctly. *In*: 2024 IEEE EVALUATION AND BEYOND - METHODOLOGICAL APPROACHES FOR VISUALIZATION (BELIV). 2024. **Anais [...]** [s.n.], 2024. p. 41–50. Disponível em: <https://ieeexplore.ieee.org/abstract/document/10756142>. Acesso em: 17 mar. 2025.
- SU, C. *et al.* Network embedding in biomedical data science. **Briefings in bioinformatics**, Oxford University Press v. 21, n. 1, p. 182–197, 2020. Disponível em: <https://academic.oup.com/bib/article/21/1/182/5228144>. Acesso em: 09 dez. 2024.
- SUMITHRA, V.; SURENDRAN, S. A review of various linear and non linear dimensionality reduction techniques. **International Journal of Computer Science and Information Technologies (IJCSIT)**, IJCSIT v. 6, n. 3, p. 2354–2360, 2015. Disponível em: <https://citeseerx.ist.psu.edu/document?repid=rep1&type=pdf&doi=ed2fc78cf5d7eb8233deaa9dde8f42b1e2d7f661>. Acesso em: 09 dez. 2024.
- UCAR, A.; KARAKOSE, M.; KIRIMÇA, N. Artificial intelligence for predictive maintenance applications: key components, trustworthiness, and future trends. **Applied Sciences**, MDPI v. 14, n. 2, p. 898, 2024. Disponível em: mdpi.com/2076-3417/14/2/898. Acesso em: 09 dez. 2024.
- VELLIANGIRI, S.; ALAGUMUTHUKRISHNAN, S.; JOSEPH, S. I. T. A review of dimensionality reduction techniques for efficient computation. **Procedia Computer Science**, Elsevier B.V. v. 165,, p. 104–111, 2019. Disponível em: <https://sciencedirect.com/science/article/pii/S1877050920300879>. Acesso em: 09 dez. 2024.
- WAN, L. *et al.* Effect of oral faecal microbiota transplantation intervention for children with autism spectrum disorder: A randomised, double-blind, placebo-controlled trial.

Clinical and Translational Medicine, v. 14, n. 9, p. e70006, 2024. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11347384/>. Acesso em: 17 mar. 2025.